

Übungsblatt 6

Data Engineering

5430UE Web and Data Engineering

Prof. Dr. Michael Granitzer

24 März 2026

Lernziele

- **Big Data** anhand der 5 V's (Volume, Velocity, Variety, Veracity, Value) charakterisieren
- **Batch- vs. Streaming-Verarbeitung** unterscheiden und das **CAP-Theorem** anwenden
- **Data Warehouse** und **Star Schema** entwerfen; **OLAP vs. OLTP** abgrenzen
- Data-Mining-Grundlagen (**KDD-Prozess**, **CRISP-DM**) und Data-Science-Workflows einordnen
- **MapReduce** und **HDFS** als verteilte Verarbeitungsbausteine verstehen
- **Sampling, Klassifikationsmetriken** (Precision, Recall, F1) und Datenqualität bewerten

Modul A

Big Data Grundlagen

Übung 6.A.1: Batch vs. Streaming

Ordnen Sie folgende Anforderungen der geeigneten Verarbeitungsart zu (Batch / Streaming / beides möglich):

Anforderung	Batch / Streaming
Tagesabschlussrechnung für alle Bestellungen	?
Echtzeit-Benachrichtigung bei verdächtiger Kreditkartentransaktion	?
Monatlicher Aktivitätsreport für alle Nutzer	?
Lagerbestand aktualisieren sobald ein Produkt verkauft wird	?
Empfehlungsmodell wöchentlich neu trainieren	?

Begründen Sie die Zuordnung bei Streaming-Fällen: Warum reicht Batch hier nicht?

Übung 6.A.2: Anwendungsbereiche von Big Data

Nennen Sie 4 verschiedene Anwendungsbereiche für Big Data. Beschreiben Sie für jeden Bereich:

a) Welche Daten werden gesammelt und wie? b) Welches der 5 Vs (Volume, Velocity, Variety, Veracity, Value) ist in diesem Bereich besonders herausfordernd? c) Welche Art von Analyse erzeugt Value aus den Daten?

Übung 6.A.3: CAP-Theorem

Das CAP-Theorem besagt, dass ein verteiltes System maximal zwei der drei Eigenschaften **Consistency**, **Availability** und **Partition Tolerance** gleichzeitig garantieren kann.

Ordnen Sie die folgenden Systeme einer CAP-Kombination zu und begründen Sie Ihre Entscheidung:

a) Traditionelle relationale Datenbank (z.B. PostgreSQL in einem Single-Node Setup) b) Apache Cassandra c) Apache Kafka

Übung 6.A.4: Die 4 V's und Datenqualität

Ein E-Commerce-Unternehmen sammelt folgende Daten:

- Clickstream-Logs: 50.000 Events/Sekunde
- Produktrezensionen: mehrsprachig, strukturiert und als Freitext
- Bestelldaten: strukturiert, transaktional
- Sensor-IoT-Daten aus Lagerhäusern: teils fehlerhafte Messwerte

Ordnen Sie je einem der 4 V's (Volume, Velocity, Variety, Veracity) die größte Herausforderung zu und beschreiben Sie eine konkrete Maßnahme.

Modul B

Data Warehouse & Datenarchitektur

Übung 6.B.1: Datenbank vs. Data Warehouse

Erklären Sie die Unterschiede zwischen einer operativen Datenbank (OLTP) und einem Data Warehouse (OLAP) anhand folgender Dimensionen:

Dimension	OLTP	OLAP
Primäre Aufgabe	?	?
Typische Abfragen	?	?
Datenmenge pro Abfrage	?	?
Aktualisierungsfrequenz	?	?
Beispiel-Technologie	?	?

Warum kann man analytische Workloads nicht einfach auf der operativen Datenbank laufen lassen?

Übung 6.B.2: Star Schema

Ein Online-Shop betreibt ein Data Warehouse. Die Faktentabelle enthält jede Bestellung mit folgenden Maßzahlen: Bestellbetrag (€), Anzahl Artikel, Rabatt (%).

- a) Skizzieren Sie das Star-Schema für dieses Data Warehouse: Welche Dimensionstabellen werden benötigt und welche Attribute enthält jede Tabelle?
- b) Schreiben Sie eine SQL-Abfrage für: „Gesamtumsatz pro Produktkategorie pro Quartal im Jahr 2024“

Modul C

Data Science & Data Mining

Übung 6.C.1: Deduktives vs. Induktives Reasoning

- a) Erklären Sie den Unterschied zwischen deduktivem und induktivem Reasoning. Geben Sie je zwei Beispiele.
- b) Welche typischen Fehlerquellen gibt es bei jedem Ansatz?
- c) Handelt es sich beim maschinellen Lernen um deduktives oder induktives Reasoning? Begründen Sie.

Übung 6.C.2: Data Mining Aufgaben klassifizieren

Ordnen Sie die folgenden Anwendungen der passenden Data-Mining-Aufgabe zu. Wählen Sie aus: **Klassifikation, Regression, Clustering, Assoziationsregeln, Collaborative Filtering**.

Geben Sie außerdem an, ob es sich um eine **prädiktive**, **deskriptive** oder **explorative** Aufgabe handelt.

a) Ein Bild wird analysiert und das System entscheidet: Hund oder Katze? b) Aus einem Foto eines Essens wird die Kalorienzahl geschätzt. c) Nutzer einer Streaming-Plattform werden anhand ihres Sehverhaltens in Gruppen eingeteilt, ohne vorgegebene Kategorien. d) Einem Nutzer werden Produkte vorgeschlagen, weil ähnliche Nutzer diese Produkte gekauft haben. e) Es wird ermittelt, welche Produkte im Supermarkt häufig zusammen in einem Einkaufskorb landen.

Übung 6.C.3: CRISP-DM Phasen

Ein Webshop möchte vorhersagen, welche Kunden in den nächsten 30 Tagen abwandern (Churn Prediction).

Beschreiben Sie für jede CRISP-DM-Phase eine konkrete Aktivität für dieses Projekt:

1. Business Understanding
2. Data Understanding
3. Data Preparation
4. Modeling
5. Evaluation
6. Deployment

Warum ist CRISP-DM ein **iterativer** Prozess? Geben Sie ein Beispiel, wann man in eine frühere Phase zurückkehren muss.

Übung 6.C.4: Data-Science-Workflows im Vergleich

CRISP-DM ist nicht der einzige standardisierte Workflow für Data-Science-Projekte. Im Lauf der Zeit haben sich mehrere alternative Modelle etabliert.

1. Beschreiben Sie kurz die folgenden Workflows und nennen Sie eine charakteristische Besonderheit:

- **CRISP-DM** (Cross-Industry Standard Process for Data Mining)
- **Blitzstein & Pfister** (Harvard CS109)
- **Philip Guo** (Forschungs-Workflow)
- **Amazon SageMaker** (Cloud-ML-Workflow)

2. Welche **gemeinsamen Phasen** finden sich in allen vier Workflows?

3. Wann wählt man einen **forschungsorientierten** Workflow (Blitzstein, Guo) und wann einen **produktorientierten** (CRISP-DM, SageMaker)?

Modul D

MapReduce & Hadoop

Übung 6.D.1: MapReduce Reducer analysieren

```
import sys
current_word = None
current_count = 0
for line in sys.stdin:
    line = line.strip()
    word, count = line.split('\t', 1)
    try:
        count = int(count)
    except ValueError:
        continue
    if current_word == word:
        current_count += count
    else:
        if current_word:
            print('%s\t%s' % (current_word, current_count))
            current_count = count
            current_word = word
        if current_word == word:
            print('%s\t%s' % (current_word, current_count))
```

a) Was macht dieser Code? Erklären Sie die Logik. b) Warum muss die Eingabe **sortiert nach Wort** sein, damit der Code korrekt funktioniert? c) Was ist die Ausgabe für die Eingabe (sortiert): Hallo\t1, Hallo\t1, Welt\t2?

Übung 6.D.2: MapReduce Mapper schreiben

Schreiben Sie einen Python Mapper (`map.py`), der Sätze von `stdin` einliest und für jedes Wort eine Zeile der Form `WORT\t1` ausgibt. Berücksichtigen Sie:

- Großschreibung ignorieren (alles in Kleinbuchstaben)
- Satzzeichen am Wortende entfernen (`.,!?:;`)
- Leere Wörter überspringen

Testen Sie den kompletten Workflow mit:

```
echo "Ein Haus an einem Haus könnte ein kleines Haus oder eine Garage sein." \  
| python map.py | sort -k1,1 | python reduce.py
```

Was ist die erwartete Ausgabe?

Übung 6.D.3: Hadoop HDFS Konzepte

- a) In welche Komponenten ist HDFS aufgeteilt und was ist die Aufgabe jeder Komponente?
- b) Eine Datei wird in HDFS mit einem Replikationsfaktor von 3 gespeichert und hat eine Größe von 200 MB (Chunk-Größe: 64 MB). Wie viele Chunks entstehen und wie viele Chunk-Kopien existieren insgesamt? Wie viel Speicher wird insgesamt belegt?
- c) Was bedeutet **Data Locality** und warum ist es für die MapReduce-Performance entscheidend?

Modul E

Statistik und Machine Learning Grundlagen

Übung 6.E.1: Random Sampling — Einfach vs. Stratifiziert

Ein Forschungsteam möchte eine Stichprobe von 500 Studierenden aus einer Hochschule mit 5.000 Studierenden ziehen.

Fakultät	Studierende	Anteil
Informatik	1.000	20%
Wirtschaft	2.000	40%
Ingenieurwesen	1.500	30%
Geisteswissenschaften	500	10%

1. Wie viele Studierende kämen bei **einfacher Zufallsstichprobe** aus jeder Fakultät? Ist das ein Problem?
2. Wie viele Studierende würden bei **stratifizierter Stichprobe** aus jeder Fakultät gezogen? Welcher Vorteil?
3. Wann ist einfache Zufallsstichprobe ausreichend, wann ist Stratifizierung notwendig?

Übung 6.E.2: Machine Learning — Wahrscheinlichkeit und Klassifikation

Ein Modell zur Erkennung handgeschriebener Ziffern wird auf 10.000 Testbildern evaluiert.

Gegeben:

- Gesamtgenauigkeit (Accuracy): 97 %
 - Das Modell klassifiziert die Ziffer „4“ in 95 % aller Fälle korrekt
 - Die Ziffer „4“ macht 10 % aller 10.000 Testbilder aus
 - 8 % der als „4“ klassifizierten Bilder sind tatsächlich keine „4“
1. Wie viele der 10.000 Testbilder zeigen eine „4“? Wie viele werden korrekt erkannt?
 2. Was ist der Unterschied zwischen **Precision** und **Recall**? Berechnen Sie Precision für die Klasse „4“.
 3. Warum ist **Accuracy** alleine kein ausreichendes Gütekriterium bei ungleicher Klassenverteilung?

Materialien zum Übungsblatt

Zur Vertiefung der Data-Engineering-Konzepte stehen folgende Materialien bereit:

Data-Science-Workflow-Vergleich

- [datascience-workflow-crispdm.png](#) — CRISP-DM
- [datascience-workflow-blitzstein-pfister.png](#) — Blitzstein/Pfister
- [datascience-workflow-gao.png](#) — Philip Guo
- [datascience-workflow-amazon-sagemaker.png](#) — Amazon SageMaker
- [datascience-workflow.png](#) — generischer DS-Workflow

Sampling und Klassifikation

- [simple-random-sampling-with-replacement.png](#), [simple-random-sampling-without-replacement.png](#)
- [inference-example.png](#), [inference-example-classification.png](#)
- [mnist-wikipedia.png](#) — MNIST-Beispiel

MapReduce

- [mapreduce-test.txt](#) — Beispiel-Eingabedatei für MapReduce-Aufgaben



*Alle Materialien finden Sie auch zentral auf der **Kursseite** unter Materials → Download.*