

Web and Data Engineering

Kapitel 02: Architektur von Web-Anwendungen

Prof. Dr. Michael Granitzer

24 März 2026

Architektur gibt Antworten auf die in Vorlesung 01 beschriebene Komplexität: Wie werden einzelne Rechner zu Systemen? Wie lässt sich Skalierung von bloßem Hardware-Zuwachs trennen? Welche Entscheidungen legen die Grenzen späterer Änderungen fest? Diese Vorlesung beantwortet diese Fragen strukturiert — von Ressourcen über Prinzipien bis zu konkreten Architekturstilen.

Ziel dieser Vorlesung

Architektur bestimmt, wie Web-Systeme strukturiert, verteilt und betrieben werden. Diese Vorlesung klärt, **welche Architekturentscheidungen** typisch sind, **warum** sie getroffen werden und **wie** sie sich auf Wartbarkeit, Skalierung und Datenverarbeitung auswirken.

Leitfragen

- Was verwaltet Software eigentlich — und warum reicht ein Rechner nicht?
- Warum ist Architektur mehr als ein Implementierungsdetail?
- Welche Architekturstile gibt es — und wie funktionieren sie?
- Wie strukturiert das 3-Schichten-Modell Web-Anwendungen?
- Wie hängen Client-Typen, Deployment und Kopplung zusammen?
- Welche Architekturen braucht die Datenverarbeitung in Web-Systemen?


Die Reihenfolge der Themen ist nicht zufällig: Hardware-Ressourcen und ihre Grenzen motivieren verteilte Systeme; Architekturprinzipien bilden das konzeptionelle Werkzeug für Entwurfsentscheidungen; konkrete Stile wie Monolith, Event-Driven und Microservices sind Antworten auf unterschiedliche Skalierungs- und Teamanforderungen; Datenarchitekturen schließen den Kreis, weil Persistenz- und Verarbeitungsstrategie maßgeblich über Skalierbarkeit und Konsistenz entscheiden.

Rechnerarchitektur und Ressourcen

Leitfrage: Was verwaltet Software eigentlich — und warum reicht ein einzelner Rechner für Web-Systeme meist nicht aus?

Die Von-Neumann-Architektur

Nahezu alle heutigen Computer folgen dem **Von-Neumann-Modell** (1945): ein gemeinsamer Speicher für Programm und Daten, eine Verarbeitungseinheit und ein sequentieller Befehlszyklus.




Software verwaltet letztlich vier physische Ressourcen: **Rechenleistung** (CPU), **Arbeitsspeicher** (RAM), **persistenter Speicher** (Storage) und **Netzwerk** (I/O). Jede Architekturentscheidung betrifft mindestens eine davon.


Hier liegt die Basiserkenntnis: Architektur ist keine Abstraktion ohne Materie. Jede Softwareentscheidung wirkt auf reale Ressourcen und damit auf Kosten, Latenz und Ausfallsicherheit.

Ressourcen eines Rechners

Ressource	Funktion	Typisch (Server)	Engpass-Symptom
CPU	Berechnung, Steuerung	8–128 Kerne	hohe Latenz, lange Antwortzeiten
RAM	aktive Daten	32–512 GB	Out-of-Memory, Swapping
Storage	persistente Daten	TB bis PB	langsame Reads/Writes
Netzwerk	Kommunikation	1–100 Gbit/s	Timeouts, Paketverlust



Prozesse und Threads



- **Prozess:** Eine laufende Instanz eines Programms mit eigenem, isoliertem Speicherbereich.
- **Thread:** Ein leichtgewichtiger Ausführungsstrang innerhalb eines Prozesses, der sich den Speicher mit anderen Threads desselben Prozesses teilt.

Prozess vs. Thread

	Prozess	Thread
Speicher	eigener Adressraum	teilt Prozess-Speicher
Isolation	stark	schwach
Erzeugung	aufwändig	leichtgewichtig

Ein Web-Server bedient viele gleichzeitige Requests. Ob er Threads, Prozesse oder asynchrone Events nutzt, ist eine zentrale Designentscheidung — bestimmt Durchsatz und Ressourcenverbrauch.

Diese Gegenüberstellung macht klar, dass Parallelität nicht kostenlos ist. Die Wahl des Ausführungsmodells ist bereits Architektur.

Warum ein Rechner nicht reicht

Grenzen einzelner Rechner (Faustregeln)

- **CPU:** Einfache HTTP-Requests: Tausende/s — rechenintensive Operationen (ML, Bildverarbeitung) deutlich weniger
- **RAM:** $100.000 \text{ Sessions} \times 1 \text{ MB} = 100 \text{ GB}$ — Sessiongröße ist entscheidend
- **Storage I/O:** SSD: 10.000–100.000 IOPS — komplexe DB-Queries können das schnell ausschöpfen
- **Netzwerk:** $10 \text{ Gbit/s} = 1,25 \text{ GB/s}$ — bei 10.000 Nutzern $\times 1 \text{ Mbit/s}$ bereits voll ausgelastet


Skalierungsstrategien

Strategie	Beschreibung	Grenze
Vertikal skalieren	Mehr RAM, schnellere CPU, größere SSD	Physische und ökonomische Obergrenze
Horizontal skalieren	Mehr Server, Last verteilen	Koordination, Konsistenz, Netzwerk

Konkrete Zahlen sind immer Faustregeln und stark workload-abhängig. Ziel ist das Verständnis der Größenordnungen und Engpass-Typen, nicht exakte Benchmarks.



Vom einzelnen Rechner zum verteilten System



Neue Herausforderungen: Netzwerklatenz · Partielle Ausfälle · Datenkonsistenz · Koordination

Neue Herausforderungen

- **Netzwerk-Latenz** — ms statt ns (RAM)
- **Partielle Ausfälle** — einzelne Server fallen aus
- **Konsistenz von Software** — welche Version ist aktuell?
- **Koordination von Prozessen** — wer bearbeitet was?

Es entstehen neue Architekturentscheidungen

Die Botschaft ist: Ein verteiltes System ist keine Eleganzübung, sondern die Konsequenz aus Ressourcen- und Skalierungsgrenzen.

Takeaway

Software-Architektur verwaltet physische Ressourcen: CPU, RAM, Storage und Netzwerk. Ein einzelner Rechner hat endliche Kapazität — sobald diese nicht mehr ausreicht, entsteht ein verteiltes System mit neuen Herausforderungen (Latenz, Ausfälle, Konsistenz).

Schlüsselbegriffe

Begriff	Erklärung
Von-Neumann-Architektur	Rechnermodell mit gemeinsamem Speicher für Programm und Daten
Prozess	Laufende Instanz eines Programms mit eigenem Speicherbereich
Thread	Leichtgewichtiger Ausführungsstrang innerhalb eines Prozesses
Concurrency	Mehrere Aufgaben machen Fortschritt — durch Scheduling auf einem Kern
Parallelismus	Mehrere Aufgaben laufen gleichzeitig auf verschiedenen Kernen
Vertikale Skalierung	Leistungsstärkere Hardware für einen Server (Scale Up)
Horizontale Skalierung	Last auf mehrere Server verteilen (Scale Out)

Vertikale Skalierung (stärkere Hardware) stößt physisch an Grenzen und erzeugt Single Points of Failure. Horizontale Skalierung (mehr Instanzen) erfordert zustandslose Komponenten, Load Balancing und verteilte Datenhaltung — sie ist aufwändiger, aber unbegrenzt skalierbar. In der Praxis werden beide kombiniert: vertikale Skalierung für die Datenbankschicht, horizontale für die Applikationsschicht.

Software-Architekturen

Leitfrage: Warum lohnt es sich, eine Web-Anwendung architektonisch zu zerlegen, bevor über Frameworks oder Programmiersprachen entschieden wird?

Was ist Software-Architektur?

„The software architecture of a system is the set of structures needed to reason about the system, which comprise software elements, relations among them, and properties of both.”

— Bass, Clements & Kazman, Software Architecture in Practice (4th ed.)

Software-Architektur beschreibt die **oberste Struktur** eines Systems — die schwer änderbaren Entscheidungen und die Beziehungen zwischen den wichtigsten Teilen.

Architekturentscheidungen sind diejenigen, deren nachträgliche Änderung unverhältnismäßig hohen Aufwand erzeugt — etwa die Wahl des Datenbankmodells, des Kommunikationsmusters zwischen Komponenten oder der Deployment-Einheit. Implementierungsentscheidungen (Klassenname, Algorithmusdetail) sind dagegen lokal reversibel. Diese Asymmetrie erklärt, warum Architekturarbeit früh im Entwicklungsprozess den höchsten Hebel hat.

Typische Ziele

- Komplexität reduzieren
- Verantwortlichkeiten trennen
- Schnittstellen stabilisieren
- Wartung und Weiterentwicklung vorbereiten
- Sicherstellen von
 - Skalierbarkeit
 - Testbarkeit
 - Zuverlässigkeit
 - Sicherheit
 - Performance
 - ...

Die Liste ist bewusst breit. Architektur ist immer ein Kompromiss zwischen Qualitätszielen, nie nur ein einzelnes Kriterium.

Architekturentscheidung vs. Implementierung

	Architekturentscheidung	Implementierungsentscheidung
Änderungskosten	hoch — betrifft viele Komponenten	gering — lokal begrenzt
Beispiel Web	„Monolith oder Microservices?“	„Welches ORM nutzen wir?“
Beispiel Web	„REST oder GraphQL als API-Stil?“	„Welche HTTP-Library?“
Beispiel Web	„Wo liegt Session-State — Client oder Server?“	„Redis oder Memcached als Cache?“
Lebensdauer	Jahre — schwer revidierbar	Wochen bis Monate — austauschbar

Faustregel: Wenn eine Entscheidung **teuer zu revidieren** ist und **viele Teile des Systems betrifft**, ist sie architektonisch.

Diese Faustregel ist praktisch wichtiger als jede Definition. Sie hilft bei der täglichen Unterscheidung zwischen "Design" und "Implementierung".

Architektonische Prinzipien

Prinzip	Kernaussage	Schlecht	Gut
Separation of Concerns	Jede Komponente hat eine klar abgegrenzte Verantwortung	<code><p><?= \$db->query(...) ?></p></code>	Controller → Service → Repository → DB
Single Responsibility	Ein Modul tut genau eine Sache	OrderService speichert + mailt + berechnet Steuer	OrderService + EmailService + TaxService
Principle of Least Knowledge	Komponenten kennen nur die Schnittstelle — nicht die Interna	Service A liest direkt von DB Daten aus Service B	Service A ruft Service B per API auf
Build to Change	Architektur für Änderungen entwerfen, nicht für Stabilität	Interne Felder direkt exponiert, kein Versionierungskonzept	API-Versionierung, Feature Flags
DRY - Dont Repeat Yourself	Logik nicht duplizieren	Validierung separat in Client und Server	Validierung zentral — einmal definiert, überall verwendet
YAGNI - You Aint Gonna Need it	Nur bauen, was jetzt gebraucht wird	Microservice-Setup für ein Drei-Personen-Team	Monolith starten, erst bei echtem Bedarf aufteilen
KISS - Keep It Simple, Stupid	Komplexität vermeiden	Microservice-Setup für ein Drei-Personen-Team	Monolith starten, erst bei echtem Bedarf aufteilen

Die Prinzipien sind keine Dogmen. Sie sind Abkürzungen für wiederkehrende Erfahrungen, die helfen, Wartbarkeit und Änderbarkeit aktiv zu schützen.

Warum Architektur für Web-Systeme zählt

Web-Anwendungen kombinieren viele Technologien und Verantwortlichkeiten in einem System. Ohne explizite Architektur wachsen Abhängigkeiten unkontrolliert.

Situation	Ohne Architektur	Mit Architektur
Datenbank wechseln	Änderungen in hunderten Dateien, da SQL direkt im Code	Data Access Layer austauschen, Rest bleibt stabil
Mobile App ergänzen	Backend liefert HTML — App braucht JSON-API → großer Umbau	API existiert bereits, Mobile Client wird angebunden
Team wächst	Alle arbeiten im selben Code, ständige Konflikte	Klare Modulgrenze, Teams arbeiten unabhängig
Performance-Problem	Unklar, welche Komponente das Problem verursacht	Monitoring pro Schicht, gezielte Skalierung möglich

Typische Architekturfragen

Bevor Code geschrieben wird, sollten diese Fragen beantwortet sein:

- Welche Teile dürfen direkt voneinander abhängen?
- Wo liegt Geschäftslogik — im Client, im Server, in einem separaten Service?
- Welche Entscheidungen müssen lange stabil bleiben?
- Wie wird das System deployt — als Monolith, als Container, als serverless Functions?
- Welche Querschnittsthemen (Sicherheit, Logging, Monitoring) betreffen mehrere Komponenten?
- Wie kommunizieren die Teile — synchron per API oder asynchron per Events?


Architektur ist keine Zusatzdokumentation. Sie ist das Mittel, um ein komplexes Web-System überhaupt beherrschbar zu machen.

Der Punkt ist nicht Dokumentationspflege, sondern Steuerbarkeit. Architektur ist eine Arbeitsgrundlage für Entwicklung und Betrieb.

Architekturstile für Web-Anwendungen

Leitfrage: Welcher Architekturstil passt zu einer Web-Anwendung, wenn sich Anforderungen, Lastprofil und Teamstruktur unterscheiden?

N-Tier als Referenzstil




- Einteilung in Schichten mit klaren Schnittstellen und Vereinbarungen
- eine Schicht kann nur auf die Schicht davor zugreifen (Closed Layer) oder auf alle darunter (Open Layer)
- Schichten können logische Unterteilung (Layers) oder physische Verteilung (Tiers) darstellen
- **Anwendungsbereiche:** Standard-Webanwendungen, heterogene Systeme

N-Tier: Wie funktioniert das?

Ein Request durchläuft die Schichten sequentiell — die Response traversiert sie in umgekehrter Reihenfolge zurück:

1. **Client** → HTTP-Request an **Web Tier**
2. **Web Tier** → Auth, Routing, Weitergabe an **Middle Tier**
3. **Middle Tier** → Geschäftslogik, Zugriff auf **Data Tier**
4. **Data Tier** → Daten lesen/schreiben, Ergebnis zurück
5. **Middle Tier** → verarbeitetes Ergebnis an **Web Tier**
6. **Web Tier** → HTTP-Response an **Client**




Schlüsselprinzip: Jede Schicht kennt nur die Schnittstelle der nächsten — nicht deren Implementierung. Schichten sind unabhängig austauschbar und skalierbar.

Herausforderungen: Querschnittsthemen (Logging, Sicherheit) sind aufwändig; Änderungen betreffen oft mehrere Schichten gleichzeitig.

Das Referenzmodell ist bewusst simpel, weil es Kommunikationsregeln sichtbar macht. Genau diese Regeln sind in großen Web-Systemen der eigentliche Gewinn.

Event-Driven Architecture




Komponenten kommunizieren nicht direkt, sondern über **Events** — asynchrone Nachrichten, die eine Zustandsänderung beschreiben.

- **Producer** erzeugt ein Event (z.B. „Bestellung aufgegeben“)
- **Broker** (z.B. Kafka, RabbitMQ) nimmt das Event entgegen und verteilt es
- **Consumer** reagiert auf das Event unabhängig vom Producer

Event-Driven: Beispiel Bestellprozess

1. **Bestellservice** → OrderPlaced an Broker
2. Broker verteilt an **Zahlungsservice**
3. Zahlungsservice verarbeitet Zahlung → PaymentCompleted an Broker
4. Broker verteilt an **Lagerservice**
5. Lagerservice reserviert Ware




Schlüsselprinzip: Neue Consumer können hinzugefügt werden, ohne bestehende Komponenten zu ändern → hohe Entkopplung.

Herausforderungen:

- Reihenfolge nicht automatisch garantiert
- Fehlerbehandlung komplexer (Consumer-Ausfall?)
- Debugging über asynchrone Schritte schwieriger

Die Funktion des Event-Modells ist Entkopplung. Gleichzeitig zeigen die Nachteile, dass Asynchronität vor allem Betriebs- und Debugging-Arbeit verschiebt.

Microservices




Das System wird in **kleine, autonome Dienste** zerlegt — jeder mit abgegrenzter fachlicher Verantwortung und unabhängigem Deployment.

- jeder Service hat eigene Datenbank, eigenes Deployment, eigenes Team
- Kommunikation über REST-APIs, gRPC oder Events
- ein **API Gateway** routet externe Anfragen an die richtigen Services

Microservices: Beispiel Homepage-Request

1. **Client** → GET /homepage an **API Gateway**
2. Gateway ruft parallel auf:
 - User Service → Profildaten
 - Recommendations Service → Empfehlungen
 - Content Service → Katalogdaten
3. Gateway komponiert die Antworten → zusammengesetzte Response an Client




Schlüsselprinzip: Jeder Service ist autonom — eigene Sprache, eigene DB, eigener Release-Zyklus. Teams arbeiten unabhängig.

Herausforderungen:


- Netzwerklatenz, partielle Ausfälle
- Jeder Service braucht Monitoring + Deployment-Pipeline
- Service Discovery & Governance

Microservices sind eine Organisations- und Betriebsentscheidung ebenso sehr wie eine technische. Der Gewinn ist Teamautonomie, der Preis ist Koordination.


Architekturstile im Vergleich



synchron · sequentiell
klassische Web-Apps



asynchron · locker gekoppelt
Streaming · Pipelines



autonom · unabhängig deploybar
große, evolvierende Plattformen


Es gibt keinen universell besten Architekturstil. Die Wahl hängt von Domäne, Lastprofil, Änderungsrate und organisatorischem Setup ab. In der Praxis kombinieren viele Systeme mehrere Stile — z.B. N-Tier für die Kernapplikation mit Event-Driven für asynchrone Verarbeitung.

Reife Produktionssysteme kombinieren typischerweise mehrere Stile: ein monolithischer Kern für die domänenzentrale Logik, Event-Driven für asynchrone Abläufe wie Benachrichtigungen und Berichte, einzelne eigenständige Services dort, wo Teams hohe Deployment-Autonomie benötigen. Die Entscheidung zwischen Stilen hängt nicht von Präferenzen ab, sondern von Team-Größe, Änderungsfrequenz, Latenzanforderungen und Betriebskomplexität — Kriterien, die sich im Projektverlauf verschieben können.

Logisches 3-Schichten-Modell

Leitfrage: Wie lässt sich eine Web-Anwendung so strukturieren, dass Benutzeroberfläche, Logik und Datenhaltung getrennt, aber koordiniert bleiben?

Logisches 3-Schichten-Modell



Das klassische 3-Schichten-Modell teilt Anwendungssysteme in drei Schichten:

Schicht	Aufgabe
Präsentation	UI und Interaktion
Anwendung	Geschäftslogik & Regeln
Persistenz	dauerhafte Datenspeicherung

Die Anwendungsschicht kann in Dienst- und Logikschicht unterteilt werden. Dienste kapseln die Geschäftslogik und stellen Schnittstellen für die Präsentationsschicht bereit. **Layer = logische Trennung.** Mehrere Schichten können im selben Prozess laufen — physische Verteilung folgt erst im nächsten Schritt.

Was gehört in welche Schicht?

Aufgabe: Ein Nutzer kauft im Online-Shop ein Produkt. Ordnen Sie diese Code-Fragmente den drei Schichten zu:

```
// (A)
<button onclick="order()">Kaufen</button>
<p>Preis: € 79,99</p>

// (B)
if (stock < 1) throw new OutOfStockException();
double total = price * quantity * taxRate;
sendConfirmationEmail(user);

// (C)
SELECT * FROM products WHERE id = 42;
INSERT INTO orders (user_id, product_id) ...
```

Lösung

Code	Schicht	Warum
(A) HTML/Button	Präsentation	Darstellung, Nutzereingabe
(B) Lagerprüfung, Steuer, E-Mail	Anwendung	Geschäftsregeln
(C) SQL-Abfragen	Persistenz	Datenzugriff

Faustregel: Ändert sich etwas, wenn die Datenbank ausgetauscht wird? → Persistenz. Wenn das Design geändert wird? → Präsentation. Alles dazwischen → Anwendungsschicht.

Warum die Trennung praktisch wichtig ist

Ohne Schichtentrennung

```
// Alles gemischt im Controller:  
String html = "<h1>Produkt</h1>";  
ResultSet rs = db.query("SELECT ...");  
if (rs.getInt("stock") > 0) {  
    html += "<button>Kaufen</button>";  
    double tax = rs.getDouble("price") * 0.19;  
    html += "<p>€ " + tax + "</p>";  
}  
out.print(html);
```

- Datenbank wechseln → ganzen Code anfassen
- Design ändern → Geschäftslogik anfassen
- Testen ohne Datenbank → unmöglich

Mit Schichtentrennung

- **Persistenzschicht** liefert Product-Objekt
 - **Anwendungsschicht** berechnet Preis, prüft Lager
 - **Präsentationsschicht** rendert HTML/JSON
- Datenbank austauschen: nur Persistenzschicht ändern
- Design ändern: nur Präsentation ändern
- Geschäftslogik testen: ohne DB, ohne Browser

Das 3-Schichten-Modell ist keine veraltete Standardlösung, sondern eine robuste Denkstruktur. Die entscheidende Frage bei jeder Code-Zeile: **In welcher Schicht lebe ich gerade?**

Eine häufige Verletzung des Schichtenmodells ist Datenbanklogik in der Präsentationsschicht (z.B. SQL-Aufrufe im Controller oder im Template) oder Geschäftslogik in der Datenzugriffsschicht (z.B. fachliche Berechnungen im ORM-Mapping). Beides macht Schichten nicht isoliert testbar und bindet Änderungen an mehrere Stellen gleichzeitig. Das Repository-Pattern und das Service-Layer-Pattern sind verbreitete Lösungen, um diese Grenzen strukturell durchzusetzen.

3-Tier und Web-Anwendungsformen

Leitfrage: Aus welchen Komponenten besteht eine moderne Web-Anwendung — vom Browser bis zur Datenbank — und wie arbeiten diese zusammen?


Von Layer zu Tier

Perspektive	Layer	Tier
Trennung	logisch	physisch
Kommunikation	oft im selben Prozess	über Netz und Interprozesskommunikation
Hauptnutzen	Strukturierung	Verteilung, Skalierung, Isolation
Zusatzkosten	gering	Deployment, Latenz, Koordination

Layer = logische Trennung (Architekturentscheidung). **Tier** = physische Trennung (Infrastrukturentscheidung).

Anatomie einer modernen Web-Anwendung

Der Weg eines Requests vom Nutzer bis zur Datenbank durchläuft mehrere Infrastrukturkomponenten:



Jede dieser Komponenten erfüllt eine spezifische Rolle — die folgenden Slides erklären sie im Detail.

Edge-Komponenten: Vor der Anwendung

Bevor ein Request die eigentliche Anwendung erreicht, durchläuft er mehrere Schutz- und Beschleunigungsschichten:

Komponente	Aufgabe	Beispiele
DNS	Auflösung des Domainnamens zur IP-Adresse; kann geografisches Routing ermöglichen	Route 53, Cloud DNS, Azure DNS
CDN	Cacht statische Assets (JS, CSS, Bilder) an Edge-Standorten nahe am Nutzer; reduziert Latenz und Serverlast	CloudFront, Cloud CDN, Azure CDN
WAF	Filtert bösartigen HTTP-Traffic; schützt gegen OWASP Top 10 (SQL Injection, XSS, etc.)	AWS WAF, Azure WAF, Cloud Armor
DDoS-Schutz	Absorbiert volumetrische Angriffe bevor sie die Infrastruktur erreichen	AWS Shield, Azure DDoS Protection

Ohne Edge-Schutz ist die Anwendung direkt dem Internet ausgesetzt. In der Praxis sind CDN und WAF keine Extras, sondern Grundvoraussetzungen für Produktion.

Traffic-Management: Load Balancer und API Gateway

Komponente	Aufgabe	Beispiele
Load Balancer (L4/L7)	Verteilt eingehende Requests auf mehrere Instanzen; Health Checks; SSL-Terminierung	ALB, NLB, Cloud Load Balancing
API Gateway	Zentraler Einstiegspunkt für alle API-Anfragen; Routing, Authentifizierung, Rate Limiting	Kong, AWS API Gateway, Azure API Management
Reverse Proxy	Leitet Client-Requests an Backend weiter; kann SSL, Kompression und Caching übernehmen	Nginx, Envoy, Traefik

Schlüsselkonzept: Horizontale Skalierung: Load Balancer ermöglichen **horizontale Skalierung** — statt einen Server größer zu machen (vertikal), werden mehrere gleichwertige Instanzen parallel betrieben. Fällt eine Instanz aus, übernehmen die anderen.

Application Tier: Geschäftslogik

Die Anwendungsschicht enthält die eigentliche Fachlogik — Validierungen, Berechnungen, Orchestrierung von Diensten.

Typische Komponenten

Komponente	Aufgabe
Application Façade	Einheitlicher Einstiegspunkt für die Geschäftslogik; koordiniert Workflows
Business Components	Fachliche Kernlogik (z.B. Preisberechnung, Bestellvalidierung)
Business Entities	Domänenobjekte, die fachliche Konzepte abbilden
Data Access Components	Abstrahieren den Zugriff auf die Persistenzschicht (Repository Pattern)
Service Agents	Kommunikation mit externen Diensten und APIs

Cross-Cutting Concerns

- **Security:** Authentifizierung, Autorisierung, Input-Validierung
- **Operational Management:** Logging, Monitoring, Health Checks
- **Communication:** Serialisierung, Protokollhandling, Fehlerbehandlung



Asynchrone Verarbeitung: Message Queues

Nicht alle Aufgaben müssen synchron im Request-Zyklus erledigt werden. Message Queues entkoppeln zeitintensive Operationen:

Ablauf

1. **Client** → POST /order an **App Tier**
2. App speichert Bestellung in DB, legt OrderCreated-Event in **Queue**
3. App antwortet sofort mit 202 Accepted — Client wartet nicht
4. **Worker** liest Event aus Queue, sendet E-Mail, generiert PDF, aktualisiert Lager

Typische Einsatzfälle

- E-Mail-Versand, Push-Benachrichtigungen
- Bildverarbeitung, PDF-Generierung
- Synchronisation mit externen Systemen
- Langläufer: Reports, Datenexporte

Technologien

- RabbitMQ · Apache Kafka
- AWS SQS · Azure Service Bus

Caching und Data Tier

Caching


Ebene	Aufgabe	Beispiele
CDN Cache	Statische Assets am Edge	CloudFront
In-Memory	Häufig gelesene Daten im RAM	Redis, Memcached
App Cache	Sessions, berechnete Ergebnisse	Spring Cache

Data Tier

Typ	Einsatz	Beispiele
Relationale DB	Transaktionale Daten (ACID)	PostgreSQL, MySQL
NoSQL DB	Flexible Schemata	MongoDB, DynamoDB
Object Storage	Dateien, Bilder, Backups	S3, Azure Blob
Suchmaschine	Volltextsuche	Elasticsearch

3-Tier in der Cloud-Praxis

3-Tier in der Cloud



In der Cloud-Praxis wird jeder Tier in einem eigenen Subnetz isoliert:

- **Public Subnet:** Load Balancer, Web Tier
- **Private Subnet:** Application Tier, Cache
- **Isolated Subnet:** Datenbank (kein Internetzugang)
- **Security Groups** beschränken den Traffic zwischen Tiers
- **Auto Scaling** passt die Instanzanzahl pro Tier an die Last an

Client-Varianten im Vergleich

Die Verteilung von Logik zwischen Client und Server bestimmt den Anwendungstyp:

Variante	Logik im Client	Logik am Server	Typischer Einsatz
Thin Client	minimal (nur Rendering)	UI-Erzeugung + Logik + Daten	Formularsysteme, Behörden-Apps
Rich Client / SPA	UI, Routing, Zustand	API + Logik + Daten	Interaktive Plattformen, Dashboards
Mobile Client	UI, Offline-Fähigkeit, lokaler Speicher	API + Logik + Daten + Sync	Apps mit instabiler Konnektivität
API-only (Headless)	beliebig (verschiedene Clients)	nur API + Logik + Daten	Multi-Client-Plattformen

Verschiedene Technologien je nach dem Grad der Logik im Client:


Modell	Beschreibung	Typische Technologien
Server-Side Rendering (SSR)	HTML wird auf dem Server erzeugt und an den Browser gesendet	PHP, Java Servlets/JSP, Django, Rails, Next.js (SSR)
Single-Page Application (SPA)	Browser lädt einmalig eine JS-Anwendung, die danach nur noch Daten per API abruft	React, Angular, Vue.js
Hybrid (SSR + Hydration)	Server rendert initialen HTML, Browser übernimmt danach die Interaktion	Next.js, Nuxt.js, SvelteKit
Static Site + API	Statische HTML-Seiten werden vorab generiert; dynamische Daten kommen per API	Gatsby, Hugo, Astro + REST/GraphQL

Moderne Frameworks wie `Next.js` und `SvelteKit` verwischen die Grenze zwischen SSR und SPA — sie rendern serverseitig für schnelle Ladezeiten und hydrieren im Browser für Interaktivität.



Thin Client

Web Application



Merkmale

- Server erzeugt vollständiges HTML
- Browser rendert — wenig Client-Logik
- jede Interaktion = neuer HTTP-Request + voller Seiten-Reload


Einsatz

- Formulareysteme, Behörden-Apps
- einfache CRUD-Anwendungen
- überall wo Client-Ressourcen knapp sind



Rich Client / SPA

Rich Internet Application

Client



Web Server



Merkmale


- Browser lädt einmalig eine JS-Anwendung
- API-Kommunikation per AJAX/Fetch
- flüssige Interaktion ohne Seitenneuladen

Einsatz

- interaktive Plattformen, Dashboards
- hohe UI-Komplexität
- Offline-Fähigkeit möglich (Service Worker)

Mobile Client

- Eigene Präsentations-, Geschäfts- und Datenschicht im Client
- Lokaler Speicher und Cache für Offline-Fähigkeit
- Datensynchronisation über unzuverlässige Netzwerke
- Cross-Cutting: Security, Configuration, Connectivity
- Zunehmend: **Progressive Web Apps (PWAs)** als Alternative zu nativen Apps



Eine moderne Web-Anwendung besteht aus weit mehr als drei Schichten. Von CDN und WAF über Load Balancer und API Gateway bis zu Message Queues und Cache — jede Komponente hat eine spezifische Aufgabe. Die Architekturentscheidung ist, welche Komponenten man braucht und wie sie zusammenspielen.

Das logische 3-Schichten-Modell beschreibt Verantwortlichkeiten; die Infrastrukturanatomie einer modernen Web-Anwendung zeigt, wie diese Schichten betrieblich aufgeteilt sind. Zwischen Nutzer und Applikation liegen DNS-Auflösung, CDN-Edge-Caches, WAF-Filterung, Load Balancing und Reverse Proxying als eigenständige Infrastrukturschicht — jede mit eigenen Caching-, Failover- und Sicherheitseigenschaften. Die Systemgrenze liegt nicht zwischen Browser und Server, sondern zwischen öffentlicher Infrastruktur und internem Applikationskern.

Datenarchitekturen für Web-Systeme

Leitfrage: Welche Architekturmuster braucht es, um die Daten, die Web-Systeme erzeugen, systematisch zu verarbeiten und nutzbar zu machen?

Warum Datenarchitektur Teil der Web-Architektur ist

- Moderne Web-Systeme erzeugen kontinuierlich Daten: Klicks, Transaktionen, Logs, Sensorwerte
- Produktfunktionen wie Personalisierung, Dashboards und Alerting hängen direkt von Datenpipelines ab
- Ohne explizite Datenarchitektur entstehen Ad-hoc-Lösungen, die nicht skalieren und schwer wartbar sind

Datenarchitektur und Anwendungsarchitektur entwickeln sich in modernen Systemen gemeinsam. Lambda-Architektur kombiniert Batch- und Stream-Verarbeitung: ein Batch Layer für vollständige historische Analysen, ein Speed Layer für Echtzeit-Inkrementale. Kappa-Architektur vereinfacht diesen Ansatz, indem alles als Stream behandelt wird. Die Wahl zwischen diesen Ansätzen hängt davon ab, ob Konsistenz oder Latenz die dominante Anforderung ist.

Batch-Verarbeitung


Ablauf

1. **Quellen** (Web-Logs, DB, APIs) → **Ingestion**
2. Daten landen zeitgesteuert im **Data Lake** (Rohdaten)
3. **Transformation** (Spark) berechnet den Gesamtdatensatz
4. Ergebnisse fließen ins **Data Warehouse** für BI/Analyse
 - **Eigenschaften:** hoher Durchsatz, hohe Latenz (Min.-Std.)
 - **Gut für:** Reporting, ML-Training, historische Analysen

Technologien:

- Apache Spark
- Apache Airflow
- Hadoop

Batch-Verarbeitung



Batch ist stark, wenn Vollständigkeit wichtiger ist als Reaktionszeit. Das erklärt, warum viele Analyse- und ML-Pipelines weiterhin batch-orientiert bleiben.

Stream-Verarbeitung


Ablauf

1. **Producer** (Apps) senden Events an **Broker** (Kafka)
 2. **Stream Processor** (Flink) konsumiert sofort
 3. Events werden gefiltert und aggregiert
 4. **Sinks** (Dashboards, Alerts) erhalten Ergebnisse in Echtzeit
- **Eigenschaften:** niedrige Latenz (ms-s), komplexer (Order/Duplikate)
 - **Gut für:** Monitoring, Betrugserkennung, Echtzeit-Personalisierung

Technologien:

- Apache Kafka
- Apache Flink
- Spark Streaming

Stream-Verarbeitung




Stream-Verarbeitung verschiebt die Schwierigkeit von der Ausführung zur Robustheit. Echtzeit bedeutet auch mehr Verantwortung für Reihenfolge, Duplikate und Fehlerfälle.

Batch vs. Stream im Vergleich

Aspekt	Batch	Stream
Latenz	Minuten bis Stunden	Millisekunden bis Sekunden
Durchsatz	sehr hoch (große Blöcke)	hoch (Event für Event)
Komplexität	geringer (vollständiger Datensatz)	höher (Reihenfolge, Duplikate, Ausfälle)
Typischer Einsatz	Reporting, ML-Training, ETL	Monitoring, Alerting, Echtzeit-Features
Fehlerbehandlung	Neuberechnung des gesamten Batches	Checkpoints, Exactly-once-Semantik

Lambda-Architektur

Problem: Wie bekommt man sowohl historische Vollständigkeit als auch Echtzeit-Ergebnisse?



- **Batch Layer:** verarbeitet den vollständigen historischen Datensatz periodisch → exakte, aber verzögerte Ergebnisse
- **Speed Layer:** verarbeitet neue Events in Echtzeit → sofortige, aber möglicherweise approximierte Ergebnisse
- **Serving Layer:** kombiniert die Ergebnisse beider Pfade für Abfragen (Dashboard, API)


Herausforderungen:

- Doppelte Codebasis nötig (Batch + Stream)
- Hoher Betriebsaufwand
- Konsistenz zwischen Pfaden schwierig

Kappa-Architektur

Problem: Kann man die Komplexität der Lambda-Architektur reduzieren?

Kappa-Architektur



- **Unified Log:** alle Daten werden als Events persistent gespeichert (z.B. Kafka)
- **Stream Processing:** verarbeitet neue und historische Daten mit derselben Logik
- **Replay:** Neuberechnung bei Logik-Änderung durch erneutes Durchlaufen des Logs

Vorteile:

- Eine einzige Codebasis für alles
- Geringerer Betriebsaufwand
- Replay ermöglicht Korrektur

Herausforderungen:


- Replay großer Logs kann teuer sein
- nicht alles rein als Stream modellierbar

Lambda vs. Kappa im Vergleich

Aspekt	Lambda	Kappa
Verarbeitungspfade	zwei (Batch + Stream)	einer (nur Stream)
Codebasis	doppelt	einfach
Historische Daten	Batch Layer	Replay aus Event-Log
Betriebsaufwand	hoch	geringer
Genauigkeit	Batch korrigiert Stream	Replay korrigiert
Typischer Einsatz	Legacy-Systeme, komplexe Analysen	modernere Event-getriebene Systeme

Data Lake und Data Warehouse

Data Lake vs. Data Warehouse vs. Data Lakehouse



Trend: Data Lakehouse vereint Flexibilität des Data Lake mit der Struktur des Data Warehouse

Datenarchitekturen sind keine Ergänzung zur Web-Architektur, sondern ihr integraler Bestandteil. Ob Batch oder Stream, Lambda oder Kappa, Data Lake oder Warehouse — die Wahl hängt davon ab, wie schnell, vollständig und konsistent Daten verarbeitet werden müssen.

Schlüsselbegriffe

Begriff	Erklärung
Ingestion	Das Einsammeln von Rohdaten aus verschiedenen Quellen in ein zentrales System
ETL / ELT	Extract, Transform, Load — der klassische Dreischritt. Bei ELT werden Rohdaten zuerst geladen und erst im Zielsystem transformiert
Data Lake	Zentraler Speicher für Rohdaten in beliebigem Format (Schema-on-Read)
Data Warehouse	Speicher für aufbereitete, strukturierte Daten mit festem Schema (Schema-on-Write)
Message Broker	Infrastruktur (z.B. Kafka), die Events zwischen Producern und Consumern puffert
Checkpoint	Regelmäßige Momentaufnahme des Verarbeitungszustands im Stream Processing
Exactly-once-Semantik	Die Garantie, dass jedes Event genau einmal verarbeitet wird
At-least-once	Jedes Event wird mindestens einmal verarbeitet; Consumer müssen mit Duplikaten umgehen
Backpressure	Mechanismus, der den Datenfluss drosselt, wenn ein Consumer langsamer verarbeitet als der Producer liefert
Replay	Das erneute Durchlaufen eines Event-Logs; ermöglicht Neuberechnung bei Logik-Änderungen

Wrap-Up

- Software verwaltet physische Ressourcen (CPU, RAM, Storage, Netzwerk) — ihre Grenzen erzwingen Verteilung und damit Architekturentscheidungen.
- Architektur reduziert Komplexität, indem sie Verantwortlichkeiten explizit trennt.
- N-Tier, Event-Driven und Microservices lösen unterschiedliche Probleme — die Wahl hängt von Domäne, Last und Team ab.
- Das 3-Schichten-Modell trennt logisch; die physische Verteilung (Tiers) bringt Skalierung, aber auch Betriebskomplexität.
- Datenarchitekturen (Batch, Streaming, Lambda/Kappa) sind keine Ergänzung, sondern integraler Bestandteil moderner Web-Systeme.