

# Web and Data Engineering

---

## Vorlesung 06: Data Engineering

Prof. Dr. Michael Granitzer

25 März 2026

# Data Engineering

Die Vorlesung verknüpft datengetriebene Web-Systeme mit Pipelines, Speicherarchitekturen und Betriebsfragen rund um Qualität und Skalierung.

## Fokus

- wie aus Rohdaten verarbeitbare Datenprodukte werden
- wie Data Warehouse, Data Lake und Lakehouse sich unterscheiden — und warum columnar Formate (Parquet, Arrow) der gemeinsame Nenner sind
- wie das MapReduce-Paradigma entstand und sich über Spark, Flink und dbt zu modernen Verarbeitungs-Stacks weiterentwickelt hat
- warum Batch- und Stream-Verarbeitung unterschiedliche Zuschnitte brauchen und wie Lambda- und Kappa-Architektur die Integration lösen
- wie Datenqualität, Governance und Betrieb zusammenwirken

# Modul 1

---

## Datenpipelines und Datenprodukte

**Leitfrage:** Was ist Big Data — und warum überfordert es klassische Systeme?

# Welche Daten sammeln wir überhaupt?

Moderne Unternehmen und Plattformen erzeugen Daten aus sehr unterschiedlichen Quellen:

## Operative Systeme

- **Case Management:** Audit-Trails, Compliance-Daten
- **CRM / ERP:** SAP, Oracle — Kundendaten, Transaktionen
- **Service Desk:** Tickets, Vorfälle, Reaktionszeiten

## Digitale & physische Welt

- **Internet Clickstreams:** Seitenaufrufe, Klicks, Sessions
- **Netflow:** Netzwerkverkehr, Sicherheitsereignisse
- **IoT Device Events:** Sensoren, Maschinen, Fahrzeuge

Jede dieser Quellen hat eigenes Format, eigene Geschwindigkeit, eigene Vertrauenswürdigkeit.

# Was macht Daten zu „Big Data“?

## Die Fünf Vs von Big Data (IBM)

Big Data ist kein Größenbegriff, sondern ein Eigenschaftsprofil: **Volume, Variety, Velocity, Veracity, Value.**

Die klassische Datenbank-Annahme: Daten passen in Tabellen, kommen in moderatem Tempo, und sind im Wesentlichen korrekt. Alle fünf Vs stellen genau diese Annahmen in Frage.

# V1 — Volume: Das Mengenproblem

Datenmengen übersteigen, was einzelne Maschinen verarbeiten können.

## Quellen für extreme Volumina

| Bereich          | Beispiel                                     |
|------------------|----------------------------------------------|
| Web & E-Commerce | Produktaufrufe, Kaufhistorien, Reviews       |
| Banking          | Zahlungstransaktionen weltweit               |
| Social Networks  | Posts, Likes, Kommentare                     |
| LTE / 5G         | Verbindungsprotokolle, Netzwerkelektrometrie |

RDBMS wurden für einzelne, skalierbare Maschinen entworfen. Horizontale Verteilung ist nachträglich schwer einzubauen.

## Einordnung

*„Eine einzelne Google-Suche nutzt mehr Rechenleistung als die gesamte Apollo-Raumfahrtmission.“*

- Google indiziert ~10 Mrd. Seiten = ca. 200 TB
- Bei 50 MB/s Bandbreite: Lesen allein würde **40 Tage** dauern
- Lösung: Parallelisierung und verteilte Verarbeitung

# V2 — Variety: Das Formatproblem

Daten kommen nicht mehr nur als Tabellen.

| Datenmodell       | Beschreibung                                   | Beispiel                     |
|-------------------|------------------------------------------------|------------------------------|
| Relational        | Tabellen, Transaktionen, festes Schema         | Bestellungen, Konten         |
| Text              | Freitextinhalt, unstrukturiert                 | Web-Seiten, E-Mails, Tickets |
| Semi-strukturiert | Schema flexibel, hierarchisch                  | XML, JSON, Logs              |
| Graph             | Knoten und Kanten, Beziehungsnetze             | Soziale Netzwerke, RDF       |
| Streaming         | Kontinuierlicher Datenstrom, nur einmal lesbar | Sensor-Events, Klicks        |

Wenn Quellsysteme ihr Format ändern, bricht nachgelagerte Verarbeitung. **Schema-Evolution** ist ein zentrales Problem im Data Engineering.

# V3 — Velocity: Das Geschwindigkeitsproblem

Daten erscheinen mit sehr unterschiedlichen Geschwindigkeiten — und Entscheidungen müssen entsprechend zeitnah getroffen werden.

## Konkrete Zahlen

| Quelle                    | Geschwindigkeit           |
|---------------------------|---------------------------|
| Globaler Internettraffic  | ~50.000 GB/s              |
| Twitter                   | ~6.000 Tweets/Sekunde     |
| Suchanfragen (Google)     | ~100.000/Sekunde          |
| Kreditkartentransaktionen | tausende/Sekunde weltweit |

## Konsequenz für Systeme

- Systeme müssen Entscheidungen in **Millisekunden** bis Sekunden treffen
- Betrugserkennung kann nicht auf den nächsten Batch-Job warten
- Alerting auf Netzwerkanomalien erfordert Echtzeit-Verarbeitung



# V4 — Veracity: Das Vertrauensproblem

Nicht alle Daten sind verlässlich. Veracity beschreibt den Grad der Unsicherheit.

## Quellen von Datenunsicherheit

- Fehlerhafte Eingaben (Tippfehler, falsche Werte)
- Veraltete oder doppelte Datensätze
- Inkonsistente Definitionen zwischen Systemen
- Messfehler bei Sensoren
- Absichtlich verfälschte Daten (Fraud)

## Empirische Einordnung

Laut Unternehmensumfragen zweifelt **jeder dritte Entscheidungsträger** an der Qualität der Daten, auf denen Entscheidungen basieren.

Unsichere Daten führen zu unsicheren Modellen — unabhängig von Rechenleistung oder Algorithmus.

**Garbage In, Garbage Out:** Kein ML-Modell und kein Analysesystem kann systematisch fehlerhafte Eingaben kompensieren.

# V5 — Value: Das Nutzenproblem

Daten allein schaffen keinen Wert. Großmengen zu speichern ist kostspielig — der Nutzen muss aktiv erschlossen werden.

## Anwendungsfelder mit nachgewiesenem Wert

| Domäne              | Anwendung                              |
|---------------------|----------------------------------------|
| E-Commerce / Retail | Dynamic Pricing, Customer Segmentation |
| Industrie           | Predictive Maintenance                 |
| Landwirtschaft      | Smart Farming (Ertragsprognosen)       |
| Banken              | Kreditrisikomodelle, Betrugserkennung  |
| Wissenschaft        | Genomik, Klimamodellierung             |

## Wie Wert entsteht

- **Data Science:** Muster erkennen, Prognosen ableiten
- **Data Mining:** Strukturen in großen Datensätzen finden
- **Machine Learning:** Modelle auf historischen Daten trainieren

Wert entsteht durch die **Kombination** aus Daten, Methoden und fachlichem Kontext.

# Warum klassische Datenbanken scheitern

Klassische RDBMS wurden für eine Welt entworfen, die es so nicht mehr gibt:

| Annahme klassischer Systeme        | Realität bei Big Data                      |
|------------------------------------|--------------------------------------------|
| Daten passen auf eine Maschine     | Petabyte-Mengen erfordern Cluster          |
| Schema ist stabil und bekannt      | Format ändert sich laufend (Variety)       |
| Schreibvorgänge sind moderat       | Millionen Events pro Sekunde (Velocity)    |
| Daten sind im Wesentlichen korrekt | Systematische Qualitätsprobleme (Veracity) |
| Ausfälle sind Ausnahmen            | Bei 1000 Knoten: täglich Ausfälle          |

Die Fünf Vs erzwingen einen Paradigmenwechsel: von zentralisierten RDBMS zu verteilten, skalierbaren Systemen mit expliziter Qualitätskontrolle.

# Mini-Übung: Die 5 Vs im E-Commerce

Ordnen Sie jedem V ein konkretes Beispiel aus einem Online-Shop zu.

| V        | Ihre Zuordnung |
|----------|----------------|
| Volume   | ?              |
| Variety  | ?              |
| Velocity | ?              |
| Veracity | ?              |
| Value    | ?              |

# Musterlösung

| V               | E-Commerce-Beispiel                                                                     |
|-----------------|-----------------------------------------------------------------------------------------|
| <b>Volume</b>   | Klick-Logs aller Seitenbesuche (Milliarden Einträge/Tag)                                |
| <b>Variety</b>  | Produktdaten (strukturiert), Bewertungstexte (Text), Nutzersessions (Semi-strukturiert) |
| <b>Velocity</b> | Preisanpassungen in Echtzeit bei Flash-Sales                                            |
| <b>Veracity</b> | Fake-Bewertungen, fehlerhafte Produktattribute, doppelte Kundendatensätze               |
| <b>Value</b>    | Empfehlungsalgorithmus steigert durchschnittlichen Warenkorbwert                        |

Big Data ist kein Mengenproblem allein. Die fünf Vs beschreiben ein Eigenschaftsprofil, das klassische Datenbanken systematisch überfordert. Jedes V erfordert andere architektonische Antworten.

# Schlüsselbegriffe — Modul 1

| Begriff            | Erklärung                                                                                                |
|--------------------|----------------------------------------------------------------------------------------------------------|
| <b>Big Data</b>    | Datensätze, die durch Volume, Variety, Velocity, Veracity oder Value klassische Verarbeitung überfordern |
| <b>Volume</b>      | Datenmenge — von Gigabyte bis Petabyte und darüber hinaus                                                |
| <b>Variety</b>     | Vielfalt der Datenformate und -modelle (relational, Text, Graph, Stream)                                 |
| <b>Velocity</b>    | Geschwindigkeit, mit der Daten erzeugt und verarbeitet werden müssen                                     |
| <b>Veracity</b>    | Verlässlichkeit und Qualität der Daten; Unsicherheit über Korrektheit                                    |
| <b>Value</b>       | Nutzen, der durch Analyse und Anwendung aus Daten gewonnen wird                                          |
| <b>ETL</b>         | Extract, Transform, Load — klassischer Drei-Schritt-Prozess der Datenpipeline                            |
| <b>Clickstream</b> | Protokoll der Aktionen eines Nutzers auf einer Website                                                   |

# Modul 2

---

## Speicher- und Verarbeitungsschichten

**Leitfrage:** Wie gewinnt man Wissen aus Daten?

# Data Science — eine Einordnung

**Data Science** erforscht und wendet Technologien, Systeme und Algorithmen an, um Wissen aus potenziell großen, heterogenen und dynamisch veränderlichen Datensätzen zu gewinnen.

## Data Science

Methoden und Systeme zur Wissensgewinnung aus Daten — verbindet Statistik, Informatik und Domänenwissen.

## Machine Learning

Algorithmen, die aus vergangener Erfahrung lernen und Entscheidungen treffen, ohne explizit programmiert zu sein.

## Artificial Intelligence

Systeme, die intelligentes Verhalten zeigen — ML ist der aktuell dominante Ansatz, AI der übergeordnete Begriff.



# Deduktives vs. Induktives Schließen

Die Art, wie Wissen gewonnen wird, unterscheidet sich grundlegend:


| Aspekt        | Deduktives Schließen                                                               | Induktives Schließen                                                       |
|---------------|------------------------------------------------------------------------------------|----------------------------------------------------------------------------|
| Ausgangspunkt | Gegebene Prämissen und Regeln                                                      | Beobachtete Datenmuster                                                    |
| Richtung      | Allgemein → Spezifisch                                                             | Spezifisch → Allgemein                                                     |
| Ergebnis      | Logisch notwendige Schlussfolgerungen                                              | Wahrscheinliche Verallgemeinerungen                                        |
| Beispiel      | „Alle Menschen sind sterblich. Sokrates ist ein Mensch. → Sokrates ist sterblich.“ | „Diese 10.000 Kunden kauften nach A auch B. → Empfehle B nach Kauf von A.“ |
| Einsatz in DS | Regelbasierte Systeme, Constraint-Solving                                          | Machine Learning, Data Mining                                              |

**Data Science ist primär induktiv:** Muster werden aus Daten extrahiert — keine vollständige Gewissheit, aber probabilistisch fundierte Aussagen.

# Der KDD-Prozess

Knowledge Discovery in Databases (KDD) beschreibt den vollständigen Weg von Rohdaten zum Wissen:

## KDD-Prozess (Knowledge Discovery in Databases)



- **Selection:** Auswahl relevanter Daten aus dem Gesamtbestand
- **Preprocessing:** Fehlende Werte, Duplikate, Ausreißer behandeln
- **Transformation:** Merkmale ableiten, Dimensionsreduktion
- **Data Mining:** Algorithmen auf transformierten Daten anwenden
- **Interpretation:** Gefundene Muster fachlich bewerten und validieren

In der Praxis wird der Prozess mehrfach durchlaufen. Neue Erkenntnisse im Mining-Schritt führen häufig zur Überarbeitung der Preprocessing-Schritte.



# Data Mining Aufgaben im Überblick

| Kategorie   | Sub-Aufgabe             | Beschreibung                                | Beispiel                   |
|-------------|-------------------------|---------------------------------------------|----------------------------|
| Predictive  | Classification          | Klasse aus bekannten Attributen vorhersagen | Spam-Filter, Kreditrisiko  |
| Predictive  | Regression              | Numerischen Wert vorhersagen                | Preisvorhersage, Nachfrage |
| Predictive  | Collaborative Filtering | Präferenzen aus ähnlichen Nutzern ableiten  | Film-/Produktempfehlungen  |
| Descriptive | Clustering              | Ähnliche Objekte ohne Klassen gruppieren    | Kundensegmentierung        |
| Descriptive | Association Rules       | Häufig gemeinsam auftretende Muster         | Marktkorb-Analyse          |
| Descriptive | Sequential Patterns     | Zeitlich geordnete Muster                   | Klickpfad-Analyse          |
| Explorative | Anomaly Detection       | Abweichungen von Normalverhalten finden     | Betrugserkennung           |

# Classification: Vorhersage mit bekannten Klassen

## Prinzip

1. **Trainingsdaten:** Datensatz mit bekanntem Klassen-Attribut
2. **Modelltraining:** Algorithmus lernt Entscheidungsregeln
3. **Testdaten:** Modell auf unbekannte Daten anwenden
4. **Evaluation:** Genauigkeit messen (Accuracy, F1, etc.)

## Beispiel: Entscheidungsbaum

```
Alter > 30?  
├── Ja → Einkommen > 40k?  
│   ├── Ja → Kauf wahrscheinlich ✓  
│   └── Nein → Kauf unwahrscheinlich ✗  
└── Nein → Kauf unwahrscheinlich ✗
```

## Einsatz

- E-Mail: Spam oder kein Spam?
- Medizin: Diagnose aus Symptomen
- Marketing: Kauft dieser Kunde?
- Kredit: Kreditausfall wahrscheinlich?

## Algorithmen

- Decision Trees
- Random Forests
- Support Vector Machines
- Neural Networks

# Clustering: Gruppierung ohne Klassen

Clustering findet natürliche Gruppen in Daten — ohne vorgegebene Klassen.

## Beispiel: Kundensegmentierung

Cluster A: Jung, hohes Einkommen, Hochschule  
→ Premium-Angebote, digitale Kanäle

Cluster B: Mittleres Alter, mittleres Einkommen  
→ Familienprodukte, Newsletter

Cluster C: Senioren, niedriges Einkommen  
→ Basistarife, persönliche Beratung

## Eigenschaften

- kein Klassen-Attribut notwendig
- Anzahl der Cluster oft vorab wählen (k-Means)
- Ergebnisse erfordern fachliche Interpretation

## Algorithmen

- k-Means (Partitionierung)
- DBSCAN (Dichtebasiert)
- Hierarchisches Clustering

# Association Rule Mining

Findet Produkte oder Ereignisse, die häufig gemeinsam auftreten.

## Marktkorb-Analyse

| Transaktion | Produkte       |
|-------------|----------------|
| T1          | p1, p3, p5, p8 |
| T2          | p2, p5, p8     |
| T3          | p1, p5, p8     |
| T4          | p3, p4         |

Regel:  $\{p5\} \rightarrow \{p8\}$  mit Support 75%, Confidence 100%  
→ Wer p5 kauft, kauft fast immer auch p8.

## Anwendungen

- **Retail:** Platzierung verwandter Produkte
- **Online-Shop:** „Kunden, die X kauften, kauften auch Y“
- **Medizin:** Symptom-Diagnose-Korrelationen

## Kennzahlen

- **Support:** Wie oft tritt die Regel auf?
- **Confidence:** Wie zuverlässig ist die Regel?
- **Lift:** Wie viel besser als Zufall?

# Text Mining und Graph Mining

## Text Mining

Klassische Data-Mining-Methoden auf Textdaten:

- **Web-Seiten clustern:** Ähnliche Themen automatisch gruppieren
- **Seiten klassifizieren:** Spam, Kategorie, Sentiment
- **Named Entity Recognition:** Personen, Orte, Unternehmen
- **Topic Modeling:** Latente Themenstrukturen finden

Herausforderung: Texte sind hochdimensional und dünn besetzt.

## Graph Mining

Muster in Netzwerkdaten erkennen:

- **Community Detection:** Gruppen in sozialen Netzwerken
- **Link Prediction:** Wer wird mit wem verbunden?
- **Anomalie-Erkennung:** Ungewöhnliche Verbindungsmuster
- **Pagerank:** Zentrale Knoten im Netzwerk

Beispiel: Betrugserkennung über ungewöhnliche Transaktionsnetzwerke.



# Mini-Übung: Mining-Aufgaben klassifizieren

Ordnen Sie die folgenden Anwendungen einer Mining-Kategorie zu: **Classification**, **Clustering**, **Regression** oder **Collaborative Filtering**.

| Anwendung                                                       | Kategorie |
|-----------------------------------------------------------------|-----------|
| Netflix empfiehlt Serien basierend auf ähnlichen Nutzerprofilen | ?         |
| Ein Modell schätzt den Verkaufspreis eines Hauses               | ?         |
| Kunden werden nach Kaufverhalten in Gruppen eingeteilt          | ?         |
| Eine Bank entscheidet: Kreditantrag genehmigen oder ablehnen?   | ?         |

# Musterlösung

| Anwendung                                                       | Kategorie                      |
|-----------------------------------------------------------------|--------------------------------|
| Netflix empfiehlt Serien basierend auf ähnlichen Nutzerprofilen | <b>Collaborative Filtering</b> |
| Ein Modell schätzt den Verkaufspreis eines Hauses               | <b>Regression</b>              |
| Kunden werden nach Kaufverhalten in Gruppen eingeteilt          | <b>Clustering</b>              |
| Eine Bank entscheidet: Kreditantrag genehmigen oder ablehnen?   | <b>Classification</b>          |

Data Science ist die Disziplin, die aus Daten belastbares Wissen macht — durch den KDD-Prozess, induktive Lernmethoden und iterative Modellentwicklung. Wer die Aufgabe falsch wählt, erhält richtige Antworten auf die falsche Frage.

# Modul 3

---


## Batch, Streaming und Orchestrierung

**Leitfrage:** Wie verarbeitet man Daten im Petabyte-Maßstab?

# Das klassische Werkzeug: Data Warehouse

Bevor Big Data die Annahmen sprengte, war das **Data Warehouse (DWH)** die Standardantwort für analytische Datenhaltung:

ETL vs. ELT



## OLAP vs. OLTP

| Aspekt   | OLTP          | OLAP            |
|----------|---------------|-----------------|
| Zweck    | Transaktionen | Analysen        |
| Abfragen | viele, kurz   | wenige, komplex |
| Daten    | aktuell       | historisch      |
| Beispiel | Bestellsystem | Quartalsbericht |

## Star Schema


- **Faktentabelle:** Große Akkumulation numerischer Fakten
- **Dimensionstabellen:** Statische Beschreibungen von Entitäten
- **Maßzahlen:** Aggregate über Dimensionen

-  **ETL:** Daten extrahieren, transformieren, laden — klassisch

# Star Schema: Datenmodell



# Star Schema



# Warum das DWH an Grenzen stößt

Die Fünf Vs stellen die Grundannahmen klassischer DWH-Systeme direkt in Frage:

| Annahme des DWH                            | Herausforderung durch Big Data                           |
|--------------------------------------------|----------------------------------------------------------|
| Daten passen auf einen großen Server       | <b>Volume:</b> Petabyte-Mengen erfordern Verteilung      |
| Schema ist vorab bekannt                   | <b>Variety:</b> JSON, Logs, Graphen, Streams             |
| ETL läuft nachts, Latenz ist akzeptabel    | <b>Velocity:</b> Echtzeit-Anforderungen                  |
| Quelldaten sind verlässlich                | <b>Veracity:</b> Systematische Qualitätsprobleme         |
| Analytischer Mehrwert rechtfertigt Aufwand | <b>Value:</b> Kosten-Nutzen-Relation bei Rohdaten unklar |

# Data Lake: Schema-on-Read statt Schema-on-Write

Ein **Data Lake** kehrt das DWH-Prinzip um: Erst speichern, dann strukturieren.

## Konzept

- **Schema-on-Read:** Schema wird erst beim Lesen definiert — nicht beim Schreiben
- **Native Formate:** JSON, CSV, Parquet, Avro, Bilder, Audio — alle landen roh
- **Günstige Speicherung:** Object Storage (S3, Azure Blob, GCS) statt teurem RDBMS
- **Flexible Analyse:** Verschiedene Konsumenten definieren ihr Schema auf denselben Rohdaten

## Kontrast zum DWH

| Aspekt  | DWH                      | Data Lake            |
|---------|--------------------------|----------------------|
| Schema  | beim Schreiben erzwungen | beim Lesen definiert |
| Formate | nur strukturiert         | alle Formate         |

## Vorteile

| Aspekt          | Vorteil                                  |
|-----------------|------------------------------------------|
| Kosten          | Object Storage ~10× günstiger als RDBMS  |
| Flexibilität    | Neue Analysen ohne Re-ETL                |
| Vollständigkeit | Rohdaten bleiben erhalten — Replay-fähig |
| Variety         | Alle Datenformate in einer Ablage        |

## Risiko: Data Swamp

Ohne Governance wird der Data Lake zum **Data Swamp**: Hunderte Verzeichnisse ohne Dokumentation, inkonsistente Schemas, keine Zugriffsrechte — niemand weiß mehr, welche Daten aktuell und verlässlich sind.





| Aspekt       | DWH           | Data Lake                   |
|--------------|---------------|-----------------------------|
| Speicher     | RDBMS (teuer) | Object Storage<br>(günstig) |
| Änderbarkeit | starr         | flexibel                    |

Der Data Lake entstand als Reaktion auf die Starrheit des DWH: Schema-on-Write bedeutet, dass jede Schemaänderung eine ETL-Umstrukturierung erfordert. Bei schnell ändernden Datenquellen (neue App-Features, neue Event-Typen) ist das nicht praktikabel. Der Data Lake löst das durch Verzögerung: Daten landen erstmal roh, und erst beim Lesen muss sich der Konsument entscheiden, welches Schema er anlegen will. Das klingt elegant, erzeugt aber das Data-Swamp-Problem: ohne Katalog, Lineage und Qualitätsprüfungen verliert sich der Überblick schnell.

# Das Data-Swamp-Problem

Ein Data Lake ohne Governance ist nur ein teurer Papierkorb.

## Typische Symptome

- Hunderte Verzeichnisse ohne Beschreibung
- Niemand weiß, welche Dateien noch aktuell sind
- Schemas inkonsistent zwischen Erzeuger und Konsument
- Keine Zugriffsrechte → jeder liest alles (oder nichts)
- Duplikate und veraltete Snapshots häufen sich

## Ursachen

- Kein Data Catalog
- Keine Schema Registry
- Kein Lifecycle-Management (Retention)
- Fehlende Ownership



## Gegenmaßnahmen

| Problem         | Lösung                              |
|-----------------|-------------------------------------|
| Orientierung    | Data Catalog (DataHub, Atlas)       |
| Schema-Chaos    | Schema Registry (Confluent)         |
| Datenqualität   | Automatisierte Quality Gates        |
| Zugriffsrechte  | Row-/Column-Level Security          |
| Veraltete Daten | Retention Policies, Partitionierung |

*„Ein Data Swamp ist kein technisches, sondern ein organisatorisches Problem.“*


Die gleichen Governance-Maßnahmen aus Modul 4 gelten hier — aber im Data Lake sind sie noch wichtiger, weil die Struktur nicht vom Schema erzwungen wird.

## Speaker notes

Der Data Swamp ist eine der häufigsten Fallen bei der Data-Lake-Einführung. Das Problem ist systemisch: Wer Daten hineinkippt, trägt keine Kosten — wer sie später lesen will, trägt alle Kosten. Das führt zu asymmetrischen Anreizen: Produzenten schreiben, Konsumenten kämpfen. Die Lösung ist Governance-First: Kein Datensatz landet im Lake ohne Catalog-Eintrag, Schema-Dokumentation und nominellen Eigentümer. Das klingt bürokratisch, ist aber die einzige Möglichkeit, den Lake langfristig nutzbar zu halten.



# Lakehouse: Das Beste aus beiden Welten



Trend: Data Lakehouse vereint Flexibilität des Data Lake mit der Struktur des Data Warehouse

Das **Lakehouse**-Muster vereint die Kosteneffizienz des Data Lake mit der Verlässlichkeit des Data Warehouse.

Vergleich der drei Paradigmen

Implementierungen

| Eigenschaft        | DWH    | Data Lake     | Lakehouse |
|--------------------|--------|---------------|-----------|
| Speicherkosten     | hoch   | niedrig       | niedrig   |
| ACID-Transaktionen | ✓      | ✗             | ✓         |
| Schema-Enforcement | strikt | keins         | wählbar   |
| BI / SQL-Zugriff   | ✓      | eingeschränkt | ✓         |
| ML / Rohdaten      | ✗      | ✓             | ✓         |
| Time Travel        | ✗      | ✗             | ✓         |
| Offene Formate     | ✗      | ✓             | ✓         |

## Wie es funktioniert

Offene **Tabellenformate** legen eine Transaktionsschicht auf Object Storage:

- ACID-Transaktionen auf Parquet-Dateien
- Snapshot-basiertes **Time Travel** (rückwirkende Abfragen)
- Schema-Evolution ohne Breaking Changes

| Format                | Herkunft          | Besonderheit                       |
|-----------------------|-------------------|------------------------------------|
| <b>Delta Lake</b>     | Databricks (2019) | Transaction Log als JSON           |
| <b>Apache Iceberg</b> | Netflix (2018)    | Offenes Spec, breite Unterstützung |
| <b>Apache Hudi</b>    | Uber (2016)       | Upserts/Deletes auf Object Storage |

Alle drei implementieren dasselbe Konzept: ein **Manifest / Transaction Log** neben den Parquet-Dateien, das Commits, Deletes und Snapshots verwaltet.

## Warum das wichtig ist


- **DSGVO Recht auf Löschung:** Delete auf Object Storage war vorher nicht möglich
- **Upserts:** Daten korrigieren ohne kompletten Neulauf
- **Time Travel:** `SELECT * FROM tabelle AT VERSION 42`

Das Lakehouse-Konzept wurde 2020 von Databricks geprägt, aber die Idee ist älter: Netflix hatte 2018 Apache Iceberg entwickelt, um genau diese Lücke zu schließen. Das Problem: Object Storage wie S3 ist append-only — man kann Dateien hinzufügen oder löschen, aber nicht überschreiben. Für ACID-Transaktionen und DSGVO-konforme Löschungen braucht man eine Abstraktionsschicht darüber. Das ist die Rolle von Delta/Iceberg/Hudi. Sie verwalten ein Transaction Log neben den eigentlichen Parquet-Dateien und emulieren damit Transaktionen auf einem Dateisystem, das keine kennt.



# Lakehouse: Medallion Architecture

## Medallion Architecture (Lakehouse)



Die Medallion Architecture strukturiert den Datenfluss im Lakehouse in drei Schichten:

```
Object Storage (S3 / GCS / ADLS)
├── bronze/  ← Rohdaten wie angeliefert, append-only
├── silver/  ← Transformiert, bereinigt, dedupliziert
└── gold/    ← Aggregiert, für Analysen optimiert
```

| Schicht       | Inhalt                                | Konsumenten                          |
|---------------|---------------------------------------|--------------------------------------|
| <b>Bronze</b> | Rohdaten, unveränderlich, vollständig | Debugging, Replay, Reprocessing      |
| <b>Silver</b> | Bereinigt, validiert, joins aufgelöst | Data Scientists, Feature Engineering |
| <b>Gold</b>   | Aggregierte KPIs, Business-Metriken   | BI-Dashboards, APIs, Reports         |

Die Schichten bauen aufeinander auf — jede kann bei Logikfehlern neu aus der vorherigen berechnet werden. Bronze bleibt die unveränderliche Wahrheitsquelle.

Die Medallion Architecture ist eine Konvention, kein Standard — aber sie hat sich als sehr praktisch erwiesen. Bronze entspricht dem "Landing Zone"-Konzept im DWH, Silver der Staging-Schicht, Gold den Data Marts. Der entscheidende Unterschied: Im Lakehouse sind alle Schichten auf demselben Object Storage abgelegt (nur in verschiedenen Verzeichnissen), während im klassischen DWH verschiedene Systeme involviert wären. Das macht Backfilling und Reprocessing erheblich einfacher: Wenn Silver-Logik geändert wird, liest man einfach Bronze neu durch und schreibt Silver neu.

# Spaltenorientierte Speicherung: Warum Parquet?

## Spaltenorientiertes Speicherlayout

### Zeilenbasiert (RDBMS)

| id | name  | preis | kat. |
|----|-------|-------|------|
| 1  | Schuh | 49.90 | Mode |
| 2  | Hemd  | 29.90 | Mode |
| 3  | Buch  | 14.90 | Lit. |

Auf Disk gespeichert als:

[1,Schuh,49.90,Mode] [2,Hemd,29.90,Mode] [3,Buch,14.90,Lit.]

Abfrage: SELECT AVG(preis)

✗ id mitlesen

✗ na

✓ preis lesen

✗ kat.

→ 4× so viel I/O wie nötig

### Spaltenbasiert (Parquet)

| id | name  | preis | kat. |
|----|-------|-------|------|
| 1  | Schuh | 49.90 | Mode |
| 2  | Hemd  | 29.90 | Mode |
| 3  | Buch  | 14.90 | Lit. |

Auf Disk gespeichert als:

preis: [49.90, 29.90, 14.90, ...] kat: [Mode, Mode, Lit., ...]

Abfrage: SELECT AVG(preis)

✓ Nur preis-Spalte lesen — alle anderen Spalten überspringen

✓ Gleiche Werte komprimierbar: [Modex2, Lit.x1] → Run-Length

Analytische Abfragen lesen selten alle Spalten — columnar Formate sind dafür optimiert.

### Zeilenbasiert (RDBMS)



| id | name  | preis | kategorie |
|----|-------|-------|-----------|
| 1  | Schuh | 49.90 | Mode      |
| 2  | Hemd  | 29.90 | Mode      |
| 3  | Buch  | 14.90 | Literatur |

### Spaltenbasiert (Parquet)

Auf Disk gespeichert als:

id: [1, 2, 3, ...]  
name: [Schuh, Hemd, Buch, ...]  
preis: [49.90, 29.90, 14.90, ...]  
kategorie: [Mode, Mode, Literatur, ...]

Auf Disk gespeichert als:

```
[1,Schuh,49.90,Mode] [2,Hemd,29.90,Mode] ...
```

SELECT AVG(preis) muss alle anderen Felder trotzdem lesen.

**Gut für:** INSERT/UPDATE, Lesen einzelner Zeilen (OLTP)

**Schlecht für:** Aggregationen über viele Zeilen (OLAP)

SELECT AVG(preis) liest **nur** die Preisspalte.

### Vorteile:

- **Kompression:** Ähnliche Werte nebeneinander → Snappy/ZSTD: 5–10×
- **Predicate Pushdown:** WHERE kategorie='Mode' überspringt irrelevante Row Groups
- **Vektorisierung:** CPU-SIMD-Instruktionen auf homogenen Arrays


**Nicht für:** Updates einzelner Zeilen (ganze Datei-Chunks neu schreiben)

Die Intuition hinter columnar Storage: Eine analytische Abfrage wie `SELECT AVG(preis) FROM produkte WHERE kategorie = 'Mode'` braucht nur zwei Spalten — preis und kategorie. Bei row-orientierten Formaten muss der Storage-Layer trotzdem alle anderen Spalten lesen, weil sie physisch danebenstehen. Bei columnar Formaten liegen preis-Werte hintereinander, kategorie-Werte hintereinander. Das ermöglicht zwei Optimierungen: Erstens, nur relevante Spalten laden (I/O-Reduktion). Zweitens, ähnliche Werte komprimieren besser (z.B. "Mode, Mode, Mode, ..." ist trivial zu komprimieren). Und drittens: modere CPUs können 16–32 Werte parallel mit SIMD-Instruktionen verarbeiten, was bei homogenen Spalten-Arrays direkt möglich ist.

# Apache Parquet: Aufbau

Apache Parquet ist das Standard-Dateiformat für analytische Daten im modernen Data Stack:

## Dateistruktur



Der **Footer** enthält Min/Max-Werte pro Column Chunk → Parquet kann Row Groups **ohne Lesen überspringen** (Predicate Pushdown).

## Vorteile im Überblick

| Feature            | Vorteil                                  |
|--------------------|------------------------------------------|
| Columnar           | Nur relevante Spalten lesen              |
| Kompression        | Snappy / ZSTD: oft 5–10× kleiner als CSV |
| Predicate Pushdown | Row Groups überspringen ohne Scan        |
| Schema eingebettet | Selbstbeschreibend, kein Katalog nötig   |
| Nested Types       | Lists, Maps, Structs nativ unterstützt   |
| Offenes Format     | Spark, Hive, DuckDB, BigQuery, Pandas    |

**Faustregel:** Für analytische Workloads auf Object Storage immer Parquet (oder ORC) — nie CSV oder JSON für große Datensätze.

## Kompressionsbeispiel

```
kategorie-Spalte (1 Mio. Zeilen):
"Mode, Mode, Mode, Literatur, Mode, ..."
```



→ Run-Length Encoding: (Mode×847k), (Literatur×153k)  
→ 90 % Platzeinsparung



Parquet wurde 2013 von Twitter und Cloudera entwickelt und ist heute der de-facto Standard für analytische Daten in Data Lakes und Lakehouses. Der entscheidende Mechanismus ist der Footer mit Statistiken: Wenn eine Abfrage `WHERE preis > 1000` stellt und der Footer sagt, dass Row Group 3 nur Preise zwischen 10 und 50 enthält, muss diese Row Group gar nicht gelesen werden. Bei großen Datasets mit guter Partitionierung (z.B. nach Datum) kann das 90 % des I/O sparen. Das ist der Hauptgrund, warum Spark auf Parquet mit S3 oft schneller ist als auf RDBMS-äquivalenten Systemen.

# Apache Arrow: Columnar im Arbeitsspeicher

Apache Arrow ist das In-Memory-Pendant zu Parquet — dasselbe columnar Layout, aber für den RAM.

## Das Problem ohne Arrow

```
# Python liest Parquet → deserialisiert zu Python-Objekten
df = pd.read_parquet("data.parquet")
# Spark verarbeitet → Java-Heap-Objekte
# Ergebnis nach R? Erneute Serialisierung
```

Jede Systemgrenze erzwingt teures Kopieren und Konvertieren.

## Arrow: Ein gemeinsames Speicherlayout

```
Parquet auf Disk (komprimiert)
  ↓ lesen + dekomprimieren
Arrow-Buffer im RAM ← ein Format für alle
  ↓
Python / Spark / R / DuckDB
lesen denselben Buffer (zero-copy)
```

## Warum Arrow wichtig ist

| Eigenschaft        | Vorteil                                            |
|--------------------|----------------------------------------------------|
| Columnar           | SIMD-Vektorisierung durch CPU                      |
| Zero-Copy          | Kein Serialisierungs-Overhead zwischen Prozessen   |
| Sprachübergreifend | Python, Java, C++, R, Julia — ein Puffer           |
| IPC / Flight       | Hochperformante Datenübertragung zwischen Diensten |

## Parquet + Arrow: Das Standard-Paar

| Format  | Wo                    | Rolle                   |
|---------|-----------------------|-------------------------|
| Parquet | Disk / Object Storage | Komprimiert, persistent |
| Arrow   | RAM / In-Process      | Schnell, interoperabel  |



Beim Lesen: Parquet → Arrow — dasselbe Schema, minimale Konvertierung. Das ist die Basis für das moderne "zero-copy data sharing" zwischen Python, Spark und DuckDB.

Arrow wurde 2016 von der Apache Software Foundation gestartet, nachdem der Apache Drill-Entwickler Wes McKinney festgestellt hatte, dass Python (pandas), Java (Spark) und R alle ihre eigenen In-Memory-Repräsentationen für tabellarische Daten hatten. Jede Systemgrenze kostete Serialisierungszeit. Arrow definiert ein einziges binäres Layout für columnar Daten, das alle Sprachen verstehen. Das Ergebnis: Pandas kann einen Arrow-Buffer lesen, Spark kann ihn lesen, R kann ihn lesen — ohne Kopie, ohne Konvertierung. Das Ecosystem-Projekt Apache Arrow Flight erweitert das auf Netzwerk-Transport: hochperformante Datenübertragung zwischen verteilten Systemen, basierend auf demselben columnar Format.

# Scaling Up vs. Scaling Out

## Scaling Up vs. Scaling Out

### Vertical Scaling (Scale Up)

2 CPU  
16 GB



**64 CPU**  
2 TB RAM  
10.000 \$/Mo

- + Einfach (ACID funktioniert)
- + Keine verteilte Koordination
- Hardware-Maximum erreicht
- Kosten steigen überproportional

*Typisch: RDBMS, DWH*

### Horizontal Scaling (Scale Out)

Node 1

Node 2

Node 3

Node 4

Node 5

Node 6

... N

je 100 \$/Mo

- + Linear skalierbar
  - + Ausfalltoleranz durch Redundanz
  - Verteilte Koordination nötig
  - CAP-Theorem: C vs. A
- Typisch: HDFS, Spark, Cassandra*

## Vertical Scaling (Scale Up)

- Größere, leistungstärkere Einzelmaschine
- RDBMS mit ACID-Garantien funktionieren gut
- Grenze: Hardware-Maximum irgendwann erreicht
- Kosten steigen überproportional


## Horizontal Scaling (Scale Out)

- Viele kleine, günstige Standard-Maschinen
- Jenseits eines Schwellwerts günstiger als Scale Up
- Erfordert verteilte Algorithmen und Koordination
- Ausfalltoleranz durch Redundanz

# CAP-Theorem: Die Grenzen verteilter Systeme



# CAP-Theorem (Brewer, 2000)





**CAP-Theorem (Brewer, 2000):** In einem verteilten System können nicht gleichzeitig alle drei Eigenschaften garantiert werden — es müssen zwei gewählt werden.

CA

A

P

Partition Tol.

| Eigenschaft             | Bedeutung                                                    |
|-------------------------|--------------------------------------------------------------|
| Consistency (C)         | Alle Knoten sehen denselben, aktuellen Zustand               |
| Availability (A)        | Jede Anfrage erhält eine (möglicherweise veraltete) Antwort  |
| Partition Tolerance (P) | System funktioniert auch bei Netzwerkausfall zwischen Knoten |

Systemtypen in der Praxis

| Typ | Systeme                               |
|-----|---------------------------------------|
| CP  | HBase, MongoDB (strong), Zookeeper    |
| AP  | Cassandra, CouchDB, DynamoDB          |
| CA  | Klassische RDBMS (nur ohne Partition) |

lich → Wahl zwischen C und A

In der Praxis: **P muss immer gegeben sein.** Die Wahl liegt zwischen **C** und **A**.

# Der Paradigmenwechsel: SWAPPING zu CLUSTERING

## Traditionell: SWAPPING

Disk → RAM → Cache → Register

- Daten werden Block für Block von Disk geladen
  - Einzelne Maschine verarbeitet sequenziell
  - Google indiziert ~10 Mrd. Seiten = 200 TB
  - Bei 50 MB/s Bandbreite: **40 Tage** nur zum Lesen
- Selbst der schnellste Einzelrechner ist zu langsam für Petabyte-Datenmengen.

## Big Data: CLUSTERING

```
[Node 1: 10 GB Chunk] ↔ Computation  
[Node 2: 10 GB Chunk] ↔ Computation  
[Node 3: 10 GB Chunk] ↔ Computation  
... 1000 Nodes
```

- Daten in Chunks aufteilen, auf Nodes verteilen
- 200 TB / 1000 Nodes = **200 GB pro Node**
- Computation kommt zu den Daten

**Data Locality:** Code wird dorthin geschickt, wo die Daten liegen.

# Netzwerk und Ausfalltoleranz im Cluster

## Netzwerk-Bandbreite

- Innerhalb eines Racks: **1 Gbps**
- Rack-übergreifend (Backbone): **2–10 Gbps**
- Daten-Reshuffling ist teuer: 10 TB bei 1 GB/s = **2,8 Stunden**
- Faustregel: **Reshuffling minimieren**

## Ausfalltoleranz

- Bei **1000 Servern**: statistisch ~1 Ausfall pro Tag
- Bei **1.000.000 Maschinen** (Google): ~1000 Ausfälle täglich
- Ausfälle sind keine Ausnahmen — sie sind der **Normalzustand**

### Konsequenz:

- Daten mehrfach replizieren
- Berechnungen bei Ausfall automatisch neu starten
- Kein Job darf an einem einzelnen Knoten hängen


**Design for Failure:** Verteilte Systeme müssen von Anfang an auf Ausfälle ausgelegt sein — nicht nachträglich abgesichert werden.

# HDFS: Verteiltes Dateisystem

Das Hadoop Distributed File System (HDFS) implementiert das Clustering-Paradigma:



# HDFS — Hadoop Distributed File System



# MapReduce: Berechnung auf verteilten Daten

Google's Programmiermodell für verteilte Datenverarbeitung — heute Grundlage von Hadoop:

## Phasen


1. **Map:** Für jedes  $\langle \text{key}, \text{value} \rangle$ -Paar: erzeugt eine Menge von  $\langle k', v' \rangle$ -Paaren
2. **Shuffle & Sort:** Intermediäre Paare werden nach Key gruppiert und sortiert
3. **Reduce:** Für jede Gruppe von  $\langle k', v' \rangle$ -Paaren: berechnet ein Aggregat

## Effizienz-Prinzipien

- **Streaming through data:** Sequenzielles Lesen ohne Disk Seeks
- **Data Locality:** Map-Tasks laufen auf dem Knoten mit dem jeweiligen Chunk
- **Automatische Fehlerbehandlung:** Fehlgeschlagene Tasks werden neu gestartet

# MapReduce Beispiel: Wörter zählen

## MapReduce: Word Count Beispiel



### map(key, value):

```
for word in value.split():  
    emit(word, 1)
```

### reduce(key, values):

```
emit(key, sum(values))
```

### Effizienz-Prinzipien:

1. Data Locality — Map läuft auf dem Chunk-Node
2. Streaming — Sequenzielles Lesen, keine Seeks
3. Parallelisierung — alle Mapper gleichzeitig
4. Fehlertoleranz — Tasks automatisch neu starten

```
# Pseudo-Code: MapReduce Wortfrequenz  
def map_fn(key, value):  
    # value = Zeile des Dokuments  
    for word in value.split():  
        emit(word, 1)  
  
def reduce_fn(key, values):  
    # key = Wort, values = [1, 1, 1, ...]  
    emit(key, sum(values))
```

# MapReduce als funktionales Paradigma

MapReduce ist keine Hadoop-Erfindung — es ist ein Muster aus der **funktionalen Programmierung**:

## Map: Transformation

Wende eine Funktion auf jedes Element einer Collection an:

```
preise = [10.0, 25.0, 8.5]
doubled = list(map(lambda x: x * 2, preise))
# → [20.0, 50.0, 17.0]
```

Jedes Element ist **unabhängig** — beliebig parallelisierbar.

## Reduce: Aggregation

Fasse eine Collection auf einen Wert zusammen:

```
from functools import reduce
total = reduce(lambda a, b: a + b, preise)
# → 43.5
```

## Dasselbe in SQL



## Warum das skaliert

1000 Knoten, je 1 GB Chunk:

```
[Chunk 1] → map() → [k', v']
[Chunk 2] → map() → [k', v']
[Chunk 3] → map() → [k', v']
```

→ reduce() → Ergebnis

## Schlüsseleigenschaft:

- Map-Phase: vollständig parallel, kein Knoten kennt andere
- Reduce-Phase: Aggregation über Schlüssel — nur minimales Reshuffling nötig

## Skalierbarkeit aus zwei Garantien:

1. map ist **nebeneffektfrei** — keine gemeinsamen Seitenzustände
2. reduce ist **assoziativ** —  $\text{reduce}(a, \text{reduce}(b, c)) = \text{reduce}(\text{reduce}(a, b), c) \rightarrow$



```
SELECT kategorie, AVG(preis) -- Reduce
FROM produkte
GROUP BY kategorie          -- Shuffle + Group
-- implizites Map: alle Zeilen durchlaufen
```

## Teilergebnisse kombinierbar

Jede Funktion, die diese Garantien erfüllt, lässt sich auf beliebig vielen Knoten parallel ausführen.

Das MapReduce-Paradigma geht auf LISP (1958) zurück — `map` und `reduce` (dort `fold`) sind funktionale Grundoperationen. Google hat 2004 erkannt, dass diese Abstraktion exakt die richtige ist, um verteilte Berechnungen zu modellieren. Der Trick ist die Nebeneffektfreiheit: Wenn eine Funktion nur ihre Eingabe liest und keine globalen Zustände verändert, kann das Framework beliebig viele Kopien davon parallel starten, ohne Koordination zu benötigen. Das ist der Grund, warum MapReduce so elegant skaliert — die Parallelisierung ist nicht ein nachträgliches Engineering-Problem, sondern eine Konsequenz der Abstraktionswahl.

# Grenzen von klassischem MapReduce

Googles Original-MapReduce (2004) hat strukturelle Schwächen, die seinen Nachfolgern den Weg bereiteten:

| Problem               | Ursache                                          | Konsequenz                                                |
|-----------------------|--------------------------------------------------|-----------------------------------------------------------|
| Disk-Intensiv         | Jede Phase schreibt intermediäre Daten auf HDFS  | 10–100× langsamer als nötig für iterative Algorithmen     |
| Zwei-Phasen-Modell    | Nur Map + Reduce als Primitive                   | Komplexe Jobs = viele sequentielle MR-Jobs hintereinander |
| Kein Iterator-Zustand | Reducer erhält alle Werte auf einmal in Speicher | Joins und Iterationen (ML-Training!) teuer                |
| Java-First            | Hoher Boilerplate für einfache Transformationen  | Produktivitätsproblem für Analysten                       |
| Kein Streaming        | Nur Batch                                        | Neue Latenzanforderungen nicht erfüllbar                  |

*Google selbst hat MapReduce intern 2014 durch **Millwheel** (Streaming) und **FlumeJava** (Pipelines) ersetzt — und später durch Dataflow. Hadoop/MapReduce bleibt in der Praxis weit verbreitet, aber kein aktives Entwicklungsziel mehr.*

Der entscheidende Bottleneck von klassischem MapReduce: ML-Algorithmen wie k-Means oder PageRank sind iterativ — sie brauchen denselben Datensatz 10, 50, 100 Mal. Bei jedem Durchlauf schreibt MapReduce alle intermediären Daten auf HDFS (wegen Ausfalltoleranz), liest sie im nächsten Durchlauf wieder ein. Das sind für eine 100-GB-Datensatz  $10 \times 100 \text{ GB}$  Lesen + Schreiben = 2 TB I/O für 100 Iterationen, obwohl die Daten sich nicht geändert haben. Spark löst das durch In-Memory-Caching: nach dem ersten Lesen bleiben die Daten im RAM der Worker-Prozesse und können ohne Disk-Zugriff wiederverwendet werden.

# Von MapReduce zu Apache Spark

Apache Spark (AMPLab Berkeley, 2009) löst das Disk-Bottleneck durch In-Memory-Verarbeitung:

## Resilient Distributed Datasets (RDD)

```
# Spark RDD (Scala/Python API)
rdd = sc.textFile("hdfs://logs/*.txt")

result = (rdd
    .flatMap(lambda line: line.split()) # map
    .map(lambda word: (word, 1))         # map
    .reduceByKey(lambda a, b: a + b)     # reduce
    .sortBy(lambda x: -x[1]))           # sort

result.saveAsTextFile("hdfs://output/")
```

- **Lazy Evaluation:** Operationen werden erst bei `.save()` / `.collect()` ausgeführt
- **Lineage-Graph:** Bei Ausfall wird nur der betroffene Partition neu berechnet
- **In-Memory-Caching:** `rdd.persist()` hält Daten im RAM für Wiederverwendung

## DataFrame API + Catalyst-Optimizer (2015)

```
# Spark DataFrame – SQL-nahe Syntax
from pyspark.sql import functions as F

result = (spark.read.parquet("s3://data/")
    .filter(F.col("kategorie") == "Mode")
    .groupBy("hersteller")
    .agg(F.avg("preis").alias("avg_preis")))
    .orderBy("avg_preis", ascending=False))
```

- **Catalyst:** Algebraische Query-Optimierung (wie SQL-Planer)
- **Tungsten:** CPU- und Speicher-Optimierung, Code-Generierung
- **Unified:** Batch, Streaming, ML (MLlib), Graph (GraphX) in einer API
- **Spark SQL:** Direkte SQL-Abfragen auf DataFrames

Spark ist der wichtigste Nachfolger von MapReduce und heute das dominierende Framework für verteilte Batch-Verarbeitung. Der Schlüsselvorteil gegenüber MapReduce ist das In-Memory-Caching: Spark kann einen RDD/DataFrame im RAM halten und für mehrere Operationen wiederverwenden, ohne ihn neu zu lesen. Für ML-Algorithmen mit 100 Iterationen bedeutet das 100× weniger I/O. Die DataFrame API (2015) war ein weiterer Quantensprung: Statt Java-Code schreiben Data Scientists Python oder SQL, und der Catalyst-Optimizer generiert einen effizienten physischen Plan. In der Praxis ist Spark auf Parquet-Daten in S3/GCS heute die Standard-Kombination für analytische Batch-Verarbeitung.

# Die Evolution des MapReduce-Paradigmas

2004 Google MapReduce – Disk-basiert, HDFS, Java  
↓ Problem: langsam für iterative ML, zu low-level  
2009 Apache Spark – In-Memory RDDs, 10-100× schneller  
↓ Problem: zu low-level für SQL-Analysten  
2015 Spark DataFrames + SQL (Catalyst Optimizer)  
↓ Problem: kein unified Batch + Stream API  
2016 Spark Structured Streaming + Apache Flink  
↓ Problem: Ingenieure schreiben Code, Analysten SQL  
2018 dbt (Data Build Tool) – SQL-Transformationen als versionierter Code  
↓ Problem: Python/SQL-Ökosysteme noch getrennt  
2020+ DuckDB, Polars – hochperformante In-Process Engines, Arrow-nativ

| Framework | Stärke                          | Typischer Einsatz                          |
|-----------|---------------------------------|--------------------------------------------|
| MapReduce | Einfachheit, Ausfalltoleranz    | Legacy Hadoop                              |
| Spark     | Geschwindigkeit, ML-Integration | Batch + Streaming, Feature Engineering     |
| Flink     | Exakte Streaming-Semantik       | Echtzeit, stateful Processing              |
| dbt       | SQL-Transformationen als Code   | Data Warehouse, Lakehouse Transformationen |
| DuckDB    | In-Process OLAP, Arrow-nativ    | Analytik ohne Cluster, Notebook-Workloads  |

Die Evolution des MapReduce-Paradigmas zeigt ein wiederkehrendes Muster: Jede Generation löst die Bottlenecks der vorherigen und verschiebt das Problem eine Abstraktionsebene höher. MapReduce war disk-bound → Spark löst es durch RAM. Spark war zu low-level für SQL-Nutzer → DataFrames und Spark SQL lösen es. Batch und Stream waren getrennt → Structured Streaming und Flink vereinen sie. Jetzt trennen noch Python-Code (für Ingenieure) und SQL (für Analysten) die Welt → dbt löst es durch SQL-first Transformation. Und DuckDB löst das Cluster-Overhead-Problem für kleinere Datasets: Heute lassen sich 100-GB-Analysen auf einem Laptop in Sekunden durchführen, was früher ein Hadoop-Cluster erfordert hätte.




# Stream-Zeitmodelle: Warum Reihenfolge trügt

Im Streaming ist Zeit nicht trivial — dasselbe Event hat drei verschiedene Zeitstempel:

## Stream-Zeitmodelle


### Event Time

Wann ist das Event tatsächlich passiert?



### Ingestion Time

Wann ist das Event beim Broker (Kafka) eingetroffen?



### Processing Time

Wann hat Flink/Spark das Event verarbeitet?



**Kernproblem: Events treffen nicht in der Reihenfolge ein, in der sie passiert sind. Stream-Systeme brauchen Watermarks und Windowing, um damit umzugehen.**

# Backpressure und Exactly-Once-Semantik

Zwei zentrale Herausforderungen im Stream Processing:


## Backpressure

Was passiert, wenn der Consumer langsamer ist als der Producer?



## Exactly-Once via Checkpointing


Wie garantiert Flink, dass jedes Event genau einmal verarbeitet wird?




# Batch vs. Streaming: Wann was einsetzen?



## Batch-Verarbeitung



## Stream-Verarbeitung



## Batch-Verarbeitung

### Data Warehouse

- Daten werden gesammelt und periodisch als Block verarbeitet
- **Stärken:** Hoher Durchsatz, Einfachheit, Kosteneffizienz
- **Schwächen:** Hohe Latenz (Minuten bis Stunden)
- **Einsatz:** Reporting, ML Training, historische Analysen, ETL

### BI-Dashboard

Analytische Abfragen

## Stream-Verarbeitung



- Jedes Event wird sofort beim Eintreffen verarbeitet
- **Stärken:** Niedrige Latenz (Millisekunden)
- **Schwächen:** Komplexer (Out-of-Order, Duplikate, Checkpoints)
- **Einsatz:** Betrugserkennung, Alerting, Echtzeit-Empfehlungen

Latenz: < 1s

| Kriterium           | Batch                       | Stream                    |
|---------------------|-----------------------------|---------------------------|
| Latenz              | Minuten–Stunden             | Millisekunden–Sekunden    |
| Fehlerbehandlung    | Neuberechnung des Batchs    | Checkpoints, Exactly-once |
| Engineering-Aufwand | geringer                    | höher                     |
| Wirtschaftlichkeit  | günstiger bei großen Mengen | teurer bei hohem Volumen  |

# Lambda- und Kappa-Architektur


## Lambda- vs. Kappa-Architektur



| Aspekt                   | Lambda                | Kappa                  |
|--------------------------|-----------------------|------------------------|
| Verarbeitungspfade       | Zwei (Batch + Stream) | Einer (nur Stream)     |
| Codebasis                | Doppelt               | Einfach                |
| Historische Daten        | Batch Layer           | Replay aus Event-Log   |
| Betriebsaufwand          | Hoch                  | Geringer               |
| Genauigkeit (historisch) | Exakt                 | Abhängig von Log-Tiefe |

# Lambda-Architektur: Batch + Stream kombiniert

**Problem:** Wie bekommt man historische Vollständigkeit **und** Echtzeit-Ergebnisse?



- **Batch Layer** (Spark, Hadoop): Vollständige historische Neuberechnung periodisch — exakt, aber verzögert
  - **Speed Layer** (Flink, Kafka Streams): Nur neue Events seit letztem Batch — sofortige, approximierte Ergebnisse
  - **Serving Layer**: Kombiniert beide Pfade für Abfragen
- Nachteil — Doppelte Codebasis:** Dieselbe Verarbeitungslogik muss für Batch **und** Stream implementiert und synchron gehalten werden.

→ vollständige, exakte Modelle

Speed (Echtzeit, Kafka Streams):

Letzte 10 Klicks der aktuellen Session

→ schnelle, approximierte Updates

**Serving:**

Merge(Batch-Profil, Speed-Delta)

→ Empfehlung

**Sinnvoll wenn:** ML-Modelle wöchentliches Batch-Retraining auf vollständigen Daten brauchen + trotzdem Echtzeit-Reaktion nötig ist.




Die Lambda-Architektur wurde 2011 von Nathan Marz geprägt (Autor von Apache Storm). Das Grundproblem ist real: Batch gibt exakte, vollständige Ergebnisse — aber mit Stunden Verzögerung. Stream gibt sofortige Ergebnisse — aber möglicherweise unvollständig (weil nicht alle historischen Daten verarbeitet wurden). Lambda kombiniert beide: Der Batch Layer ist immer "korrekt" (aber veraltet), der Speed Layer ist immer "aktuell" (aber approximiert). Das Serving Layer merged beide. Das klingt elegant, erzeugt aber das "zwei Codebasen"-Problem: Jede Bugfixierung muss in Spark UND in Kafka Streams/Flink gemacht werden. Das führt in der Praxis zu Divergenz.

# Kappa-Architektur: Nur Streaming

Idee: Wenn Stream-Systeme robust genug sind — warum noch Batch?

## Kappa-Architektur



## Struktur

- Alle Daten als Events im persistenten Log (Kafka)

## Chancen und Grenzen

Stärken:

- **Eine Codebasis** — dieselbe Logik für neue Events und historische Daten
- **Replay:** Bei Logik-Änderungen gesamtes Log erneut durchlaufen → konsistente Neuberechnung

## Vergleich

| Aspekt             | Lambda      | Kappa          |
|--------------------|-------------|----------------|
| Verarbeitungspfade | zwei        | einer          |
| Codebasis          | doppelt     | einfach        |
| Historische Daten  | Batch Layer | Replay aus Log |
| Betriebsaufwand    | hoch        | geringer       |

- Korrekturen durch Replay des gesamten Logs heilbar
- Kein Batch-Framework zu betreiben
- Natürlich für Event-Sourcing-Systeme

## Grenzen:

| Herausforderung     | Ursache                                           |
|---------------------|---------------------------------------------------|
| Replay-Kosten       | 1 TB Log × 100 Partitionen = Stunden Replay       |
| Stateful Complexity | 1-Jahres-Aggregat braucht persistenten State      |
| Batch-ML-Training   | Manche Modelle brauchen echten vollständigen Scan |
| Retention           | Event-Log muss historisch ausreichend tief sein   |


**Nicht geeignet wenn:** Regulatorisches Reporting einen "frozen" Batch-Snapshot verlangt.

Die Kappa-Architektur wurde 2014 von Jay Kreps (LinkedIn, Kafka-Miterfinder) als Vereinfachung der Lambda-Architektur vorgeschlagen. Die Grundthese: Das "zwei Codebasen"-Problem von Lambda entsteht, weil Batch und Stream als verschiedene Paradigmen behandelt werden. Wenn man Batch als "Streaming mit hoher Latenz" betrachtet, braucht man nur ein Framework. Kafka als persistenter, replay-fähiger Log ist die Schlüsselkomponente: Der gleiche Event-Stream kann einmal live verarbeitet werden und einmal komplett neu durchlaufen werden (Replay), wenn sich die Verarbeitungslogik ändert. Das Problem: Replay dauert bei großen Logs Stunden bis Tage. Und einige Algorithmen (z.B. Gradient-Descent-basierte ML-Modelle) brauchen wirklich mehrfache Scans des gesamten Datensatzes — das ist auf einem reinen Stream schwer zu realisieren.

# Lambda vs. Kappa: Wann was einsetzen?

| Kriterium                | Lambda wählen                                          | Kappa wählen                                         |
|--------------------------|--------------------------------------------------------|------------------------------------------------------|
| <b>Latenzanforderung</b> | Minuten akzeptabel für historisch exakte Ergebnisse    | Sekunden durchgehend gefordert                       |
| <b>ML-Modelle</b>        | Wöchentliches Batch-Retraining auf vollständigen Daten | Online-Learning oder tägliche Inkremente ausreichend |
| <b>Compliance</b>        | Frozen Snapshots für Audit erforderlich                | Event-Log als Audit-Trail ausreichend                |
| <b>Team-Setup</b>        | Verschiedene Teams für Batch und Stream                | Ein Team, ein Framework                              |
| <b>Log-Retention</b>     | Egal (Batch-Daten auf DWH/Lake)                        | Event-Log muss historisch tief genug sein            |
| <b>Replay-Toleranz</b>   | Nicht nötig                                            | Stunden bis Tage akzeptabel                          |

**Moderner Trend:** Lakehouse + Streaming ersetzt beide Muster zunehmend. Delta Lake / Iceberg erlaubt ACID-Inserts aus Streaming-Jobs → ein einziges Storage-System für Echtzeit und Batch.



Die Praxis hat sich inzwischen weiterentwickelt: Das Lakehouse-Muster (Delta Lake, Iceberg) löst die Trennung zwischen Batch und Stream auf Storage-Ebene auf. Flink und Spark können beide in dieselben Delta-Tabellen schreiben, mit ACID-Garantien. Das Serving-Layer ist nicht mehr "Merge von zwei separaten Ergebnissen", sondern eine einzige Tabelle, die kontinuierlich aktualisiert wird. In diesem Modell ist Lambda überflüssig — und Kappa vereinfacht sich, weil der persistente State nicht mehr im Stream-Framework leben muss, sondern im Lakehouse-Format auf Object Storage.

# Mini-Übung: Batch oder Streaming?

Entscheiden Sie für jedes Szenario: **Batch** oder **Streaming** — und begründen Sie kurz.

| Szenario                                                    | Batch oder Streaming? |
|-------------------------------------------------------------|-----------------------|
| Tagesabschluss-Bericht der Verkaufszahlen                   | ?                     |
| Erkennen eines Kreditkartenbetrugs in Echtzeit              | ?                     |
| Wöchentlicher ML-Trainings-Job auf historischen Klick-Daten | ?                     |
| Alerting bei Serverausfall innerhalb von 5 Sekunden         | ?                     |
| Monatliche Kundensegmentierung für E-Mail-Kampagne          | ?                     |

# Musterlösung

| Szenario               | Entscheidung     | Begründung                                     |
|------------------------|------------------|------------------------------------------------|
| Tagesabschluss-Bericht | <b>Batch</b>     | Latenz von Stunden akzeptabel, hoher Durchsatz |
| Kreditkartenbetrug     | <b>Streaming</b> | Muss in Millisekunden entschieden werden       |
| ML-Trainings-Job       | <b>Batch</b>     | Vollständiger historischer Datensatz nötig     |
| Server-Alerting        | <b>Streaming</b> | Reaktionszeit < 5 Sekunden erforderlich        |
| Kundensegmentierung    | <b>Batch</b>     | Monatlicher Rhythmus, kein Echtzeit-Bedarf     |

Batch und Stream sind keine Konkurrenten, sondern komplementäre Werkzeuge. Die Wahl hängt von Latenzbedarf, Durchsatz und Konsistenzanforderungen ab — nicht von technischer Mode.



# Modul 4

---

## Datenqualität und Governance

**Leitfrage:** Was macht eine robuste Datenplattform aus — und warum scheitern datengetriebene Systeme oft nicht an Rechenleistung, sondern an Qualität, Verantwortlichkeiten und fehlender Transparenz?

# MapReduce: Effizienz durch Lokalität

Warum ist MapReduce so schnell, obwohl es auf tausenden günstiger Maschinen läuft?

| Prinzip               | Erklärung                                                                                     |
|-----------------------|-----------------------------------------------------------------------------------------------|
| <b>Data Locality</b>  | Map-Task läuft auf dem Node, der den Chunk speichert — kein Netzwerktransfer für Eingabedaten |
| <b>Streaming</b>      | Daten werden sequenziell gelesen, keine Disk-Seekes — maximale Bandbreite                     |
| <b>Pipelining</b>     | Map-Tasks laufen parallel auf allen Nodes — horizontale Skalierung                            |
| <b>Fehlertoleranz</b> | Framework re-startet fehlgeschlagene Tasks automatisch auf Replikat                           |

## Data Locality Principle


Code ist klein (wenige KB), Daten sind riesig (TB). **Bringe die Berechnung zu den Daten**, nicht umgekehrt.

### Geeignete Anwendungen:

- Web-Index-Aufbau (Google!)
- Log-Analyse
- ETL-Pipelines
- ML-Feature-Berechnung

# Hadoop Ökosystem

## Hadoop Ökosystem



| Schicht     | Technologien                               | Aufgabe                                          |
|-------------|--------------------------------------------|--------------------------------------------------|
| Anwendungen | MapReduce, Spark, Hive, Pig, Storm, Giraph | Datenverarbeitung (Batch, Streaming, Graph, SQL) |



| Schicht              | Technologien | Aufgabe                                          |
|----------------------|--------------|--------------------------------------------------|
| Ressourcenmanagement | YARN         | Zuweisung von CPU, RAM an Anwendungen im Cluster |
| Speicher             | HDFS         | Verteilte, redundante Datenhaltung in Chunks     |

**Hadoop ≠ MapReduce:** MapReduce ist nur **eine** Anwendung auf Hadoop. Moderne Stacks nutzen meist Spark (In-Memory, 10–100× schneller) auf YARN/HDFS.

# Alternativen zum Scale-Out

## Master/Slave Replikation

- Originaler GFS-Ansatz
- Multi-Master-Replikation möglich
- **INSERT only** — keine Updates/Deletes
- Keine JOINS → reduziert Query-Zeit
- Lesezugriff skaliert durch Replicas

**Einsatz:** Leselastige Systeme, Content-Delivery

## In-Memory-Datenbanken

- Gesamte Datenbank im RAM
- SAP HANA, Oracle In-Memory, Redis
- Extrem geringe Latenz
- Teuer, aber ideal für Echtzeitanalysen


**Einsatz:** Echtzeit-Dashboards, Trading-Systeme

## Managed Cloud-Services

- BigQuery, Redshift, Snowflake
- Serverless, automatisches Scaling
- Pay-per-Query statt Cluster-Management

# Datenqualität: Die fünf Dimensionen

| Dimension       | Prüffrage                   | Beispiel                            |
|-----------------|-----------------------------|-------------------------------------|
| Vollständigkeit | Fehlen Werte?               | 15 % der Bestellungen ohne PLZ      |
| Konsistenz      | Widersprechen sich Quellen? | CRM sagt 500 Kunden, DWH sagt 480   |
| Aktualität      | Sind Daten frisch genug?    | Lagerbestand 6 Stunden veraltet     |
| Genauigkeit     | Stimmen die Werte?          | GPS-Koordinaten auf falscher Straße |
| Eindeutigkeit   | Gibt es Duplikate?          | Gleicher Kunde mit 3 IDs            |



Qualität ist kein Feature, sondern ein Prozess: kontinuierlich messen, automatisiert prüfen, bei Verstößen alarmieren — wie Software-Tests.

# Quality Gates in der Pipeline

| Pipeline-Stufe | Quality Gate                                | Tool-Beispiel                   |
|----------------|---------------------------------------------|---------------------------------|
| Ingestion      | Schema-Validierung, Vollständigkeit, Format | Great Expectations, JSON Schema |
| Transformation | Referentielle Integrität, Wertebereiche     | dbt tests, SQL assertions       |
| Aggregation    | Plausibilitätsprüfung, Ausreißer-Erkennung  | Statistische Bounds, z-Score    |
| Serving        | Freshness-Check, SLA-Monitoring             | Airflow SLAs, Monte Carlo       |

# Was passiert bei Qualitätsverstößen?

| Strategie  | Wann?                                                   |
|------------|---------------------------------------------------------|
| Quarantäne | Fehlerhafte Datensätze in separaten Bereich verschieben |
| Abort      | Pipeline stoppen, wenn kritische Schwelle überschritten |
| Alert      | Team benachrichtigen, Daten weiterverarbeiten           |
| Auto-Fix   | Imputation fehlender Werte, Deduplication               |

**Keine dieser Strategien ist universell richtig** — die Wahl hängt vom Business-Kontext ab: Ein fehlender Sensorwert im IoT-Dashboard ist weniger kritisch als ein fehlerhafter Finanzwert.



# Data Governance: Wer ist verantwortlich?

| Governance-Frage                                   | Warum wichtig?                            |
|----------------------------------------------------|-------------------------------------------|
| <b>Ownership:</b> Wem gehört dieses Datenprodukt?  | Ohne Eigentümer wird kein Bug gefixt      |
| <b>Definitionen:</b> Was bedeutet „aktiver Kunde“? | Verschiedene Teams zählen unterschiedlich |
| <b>Zugriffsrechte:</b> Wer darf was sehen?         | DSGVO, PII, Compliance                    |
| <b>Lineage:</b> Woher kommen diese Daten?          | Debugging, Audit, Vertrauenswürdigkeit    |
| <b>Retention:</b> Wie lange speichern wir?         | Speicherkosten, Recht auf Löschung        |


## Data Catalog

Ein **Data Catalog** ist das „Google für interne Daten“:

- Beschreibung jedes Datensatzes
- Eigentümer und Kontaktperson
- Schema, Datentypen, Beispielwerte
- Lineage-Graph (Herkunft)
- Qualitätsmetriken

**Beispiele:** DataHub, Apache Atlas, Alation, Google Data Catalog

# Data Lineage: Herkunft nachvollziehen



## Warum Lineage unverzichtbar ist:

- **Debugging:** Ein Wert im Dashboard ist falsch — welche Transformation hat den Fehler eingeführt?
- **Impact Analysis:** Wir ändern das Schema einer Quelltable — welche Downstream-Systeme brechen?
- **Compliance:** Die DSGVO verlangt Auskunft, wo personenbezogene Daten verarbeitet werden
- **Vertrauen:** Data Scientists müssen wissen, ob sie einem Datensatz vertrauen können

# Mini-Übung: Quality Check Design

Ein Online-Shop hat eine Produktdaten-Pipeline: Lieferanten-CSV → Ingestion → Transformation → Data Warehouse → Produktkatalog-API.

Entwerfen Sie für jede Pipeline-Stufe **einen konkreten Quality Check**:

| Stufe          | Was prüfen Sie? | Erwartetes Ergebnis |
|----------------|-----------------|---------------------|
| Ingestion      | ?               | ?                   |
| Transformation | ?               | ?                   |
| Data Warehouse | ?               | ?                   |
| API            | ?               | ?                   |

# Musterlösung

| Stufe          | Quality Check                                       | Erwartung                                     |
|----------------|-----------------------------------------------------|-----------------------------------------------|
| Ingestion      | CSV hat alle Pflichtfelder (EAN, Name, Preis)       | Keine Zeile ohne EAN                          |
| Transformation | Preis > 0 und < 100.000 €                           | Keine negativen oder absurd hohen Preise      |
| Data Warehouse | Anzahl Produkte ändert sich max. 5 % pro Tag        | Keine Masseninsertions/-löschungen ohne Grund |
| API            | Response enthält $\geq 95$ % der Warehouse-Produkte | Keine stillen Datenverluste beim Serving      |

# Gesamtüberblick: Vom Data Warehouse zu Big Data

| Aspekt       | Klassisches DWH                  | Big Data / Cloud                         |
|--------------|----------------------------------|------------------------------------------|
| Skalierung   | Vertikal (größerer Server)       | Horizontal (mehr Nodes)                  |
| Datenmodell  | Star Schema, strukturiert        | Schema-on-Read, polyglot                 |
| Verarbeitung | ETL → OLAP                       | MapReduce, Spark, Streaming              |
| Speicher     | RDBMS (Oracle, Teradata)         | HDFS, S3, Cloud Storage                  |
| Latenz       | Stunden (Batch-ETL)              | Sekunden (Streaming)                     |
| Kosten       | Hohe Lizenzkosten, wenige Server | Commodity-Hardware, Pay-per-Use          |
| Qualität     | Manuell, selten geprüft          | Automatisierte Quality Gates             |
| Governance   | Zentral (IT-Abteilung)           | Dezentral (Data Mesh / Domain Ownership) |

**Kein Entweder-Oder:** Moderne Datenplattformen kombinieren DWH-Konzepte (Star Schema, SQL) mit Big-Data-Technologien (Spark, Cloud Storage). Das „Lakehouse“-Muster vereint Data Lake und Data Warehouse.



Data Engineering scheitert selten an Rechenleistung. Es scheitert an unklaren Eigentümerschaften, fehlender Lineage, veralteten Definitionen und ungeprüften Annahmen. Qualität, Governance und Transparenz sind keine

Add-ons — sie sind das Fundament jeder belastbaren Datenplattform.

# Wrap-Up

- **Speicherarchitekturen:** Data Warehouse (Schema-on-Write, ACID), Data Lake (Schema-on-Read, günstig, Swamp-Gefahr), Lakehouse (ACID auf Object Storage via Delta/Iceberg, Time Travel, Medallion Architecture).
- **Columnar Formate:** Parquet (Disk) und Arrow (RAM) sind das Standard-Paar für analytische Workloads — columnar komprimiert besser, liest schneller und ermöglicht Predicate Pushdown.
- **MapReduce als Paradigma:** Map (nebeneffektfrei, parallelisierbar) + Reduce (assoziativ, kombinierbar) ist das Grundmuster aller verteilten Datenverarbeitung — von Hadoop (2004) über Spark DataFrames (2015) bis dbt und DuckDB (2020+).
- **Lambda vs. Kappa:** Lambda kombiniert Batch + Stream für exakte und sofortige Ergebnisse — auf Kosten doppelter Codebasis. Kappa vereinfacht auf einen Stream-Pfad — auf Kosten von Replay-Aufwand. Moderne Lakehouses reduzieren den Unterschied.
- **Qualität und Governance:** Technisch funktionierende Pipelines werden ohne Ownership, Lineage und automatisierte Quality Gates fachlich unbrauchbar.