

Web and Data Engineering

Vorlesung 06: Data Engineering

Prof. Dr. Michael Granitzer

25 März 2026

Data Engineering

Die Vorlesung verknüpft datengetriebene Web-Systeme mit Pipelines, Speicherarchitekturen und Betriebsfragen rund um Qualität und Skalierung.

Fokus

- wie aus Rohdaten verarbeitbare Datenprodukte werden
- welche Speicher- und Verarbeitungsmodelle Data Engineering prägen
- warum Batch- und Stream-Verarbeitung unterschiedliche Zuschnitte brauchen
- wie Datenqualität, Governance und Betrieb zusammenwirken

Modul 1

Datenpipelines und Datenprodukte

Leitfrage

Was ist Big Data und warum überfordert es klassische Systeme?

Welche Daten sammeln wir überhaupt?

Moderne Unternehmen und Plattformen erzeugen Daten aus sehr unterschiedlichen Quellen:

Operative Systeme

- **Case Management:** Audit-Trails, Compliance-Daten
- **CRM / ERP:** SAP, Oracle — Kundendaten, Transaktionen
- **Service Desk:** Tickets, Vorfälle, Reaktionszeiten

Digitale & physische Welt

- **Internet Clickstreams:** Seitenaufrufe, Klicks, Sessions
- **Netflow:** Netzwerkverkehr, Sicherheitsereignisse
- **IoT Device Events:** Sensoren, Maschinen, Fahrzeuge

Jede dieser Quellen hat eigenes Format, eigene Geschwindigkeit, eigene Vertrauenswürdigkeit.

Was macht Daten zu „Big Data“?

Die Fünf Vs von Big Data (IBM)

Big Data ist kein Größenbegriff, sondern ein Eigenschaftsprofil: **Volume, Variety, Velocity, Veracity, Value.**

Die klassische Datenbank-Annahme: Daten passen in Tabellen, kommen in moderatem Tempo, und sind im Wesentlichen korrekt. Alle fünf Vs stellen genau diese Annahmen in Frage.

V1 — Volume: Das Mengenproblem

Datenmengen übersteigen, was einzelne Maschinen verarbeiten können.

Quellen für extreme Volumina

Bereich	Beispiel
Web & E-Commerce	Produktaufrufe, Kaufhistorien, Reviews
Banking	Zahlungstransaktionen weltweit
Social Networks	Posts, Likes, Kommentare
LTE / 5G	Verbindungsprotokolle, Netzwerkelektrometrie

Einordnung

„Eine einzelne Google-Suche nutzt mehr Rechenleistung als die gesamte Apollo-Raumfahrtmission.“

- Google indiziert ~10 Mrd. Seiten = ca. 200 TB
- Bei 50 MB/s Bandbreite: Lesen allein würde **40 Tage** dauern
- Lösung: Parallelisierung und verteilte Verarbeitung

RDBMS wurden für einzelne, skalierbare Maschinen entworfen. Horizontale Verteilung ist nachträglich schwer einzubauen.

V2 — Variety: Das Formatproblem

Daten kommen nicht mehr nur als Tabellen.

Datenmodell	Beschreibung	Beispiel
Relational	Tabellen, Transaktionen, festes Schema	Bestellungen, Konten
Text	Freitextinhalt, unstrukturiert	Web-Seiten, E-Mails, Tickets
Semi-strukturiert	Schema flexibel, hierarchisch	XML, JSON, Logs
Graph	Knoten und Kanten, Beziehungsnetze	Soziale Netzwerke, RDF
Streaming	Kontinuierlicher Datenstrom, nur einmal lesbar	Sensor-Events, Klicks

Wenn Quellsysteme ihr Format ändern, bricht nachgelagerte Verarbeitung. **Schema-Evolution** ist ein zentrales Problem im Data Engineering.

V3 — Velocity: Das Geschwindigkeitsproblem

Daten erscheinen mit sehr unterschiedlichen Geschwindigkeiten — und Entscheidungen müssen entsprechend zeitnah getroffen werden.

Konkrete Zahlen

Quelle	Geschwindigkeit
Globaler Internettraffic	~50.000 GB/s
Twitter	~6.000 Tweets/Sekunde
Suchanfragen (Google)	~100.000/Sekunde
Kreditkartentransaktionen	tausende/Sekunde weltweit

Konsequenz für Systeme

- Systeme müssen Entscheidungen in **Millisekunden** bis Sekunden treffen
- Betrugserkennung kann nicht auf den nächsten Batch-Job warten
- Alerting auf Netzwerkanomalien erfordert Echtzeit-Verarbeitung

V4 — Veracity: Das Vertrauensproblem

Nicht alle Daten sind verlässlich. Veracity beschreibt den Grad der Unsicherheit.

Quellen von Datenunsicherheit

- Fehlerhafte Eingaben (Tippfehler, falsche Werte)
- Veraltete oder doppelte Datensätze
- Inkonsistente Definitionen zwischen Systemen
- Messfehler bei Sensoren
- Absichtlich verfälschte Daten (Fraud)

Empirische Einordnung

Laut Unternehmensumfragen zweifelt **jeder dritte Entscheidungsträger** an der Qualität der Daten, auf denen Entscheidungen basieren.

Unsichere Daten führen zu unsicheren Modellen — unabhängig von Rechenleistung oder Algorithmus.

Garbage In, Garbage Out: Kein ML-Modell und kein Analysesystem kann systematisch fehlerhafte Eingaben kompensieren.

V5 — Value: Das Nutzenproblem

Daten allein schaffen keinen Wert. Großmengen zu speichern ist kostspielig — der Nutzen muss aktiv erschlossen werden.

Anwendungsfelder mit nachgewiesenem Wert

Domäne	Anwendung
E-Commerce / Retail	Dynamic Pricing, Customer Segmentation
Industrie	Predictive Maintenance
Landwirtschaft	Smart Farming (Ertragsprognosen)
Banken	Kreditrisikomodelle, Betrugserkennung
Wissenschaft	Genomik, Klimamodellierung

Wie Wert entsteht

- **Data Science:** Muster erkennen, Prognosen ableiten
- **Data Mining:** Strukturen in großen Datensätzen finden
- **Machine Learning:** Modelle auf historischen Daten trainieren

Wert entsteht durch die
Kombination
aus Daten, Methoden und fachlichem Kontext.

Warum klassische Datenbanken scheitern

Klassische RDBMS wurden für eine Welt entworfen, die es so nicht mehr gibt:

Annahme klassischer Systeme	Realität bei Big Data
Daten passen auf eine Maschine	Petabyte-Mengen erfordern Cluster
Schema ist stabil und bekannt	Format ändert sich laufend (Variety)
Schreibvorgänge sind moderat	Millionen Events pro Sekunde (Velocity)
Daten sind im Wesentlichen korrekt	Systematische Qualitätsprobleme (Veracity)
Ausfälle sind Ausnahmen	Bei 1000 Knoten: täglich Ausfälle

Die Fünf Vs erzwingen einen Paradigmenwechsel: von zentralisierten RDBMS zu verteilten, skalierbaren Systemen mit expliziter Qualitätskontrolle.

Mini-Übung: Die 5 Vs im E-Commerce

Ordnen Sie jedem V ein konkretes Beispiel aus einem Online-Shop zu.

V	Ihre Zuordnung
Volume	?
Variety	?
Velocity	?
Veracity	?
Value	?

Musterlösung

V	E-Commerce-Beispiel
Volume	Klick-Logs aller Seitenbesuche (Milliarden Einträge/Tag)
Variety	Produktdaten (strukturiert), Bewertungstexte (Text), Nutzersessions (Semi-strukturiert)
Velocity	Preisanpassungen in Echtzeit bei Flash-Sales
Veracity	Fake-Bewertungen, fehlerhafte Produktattribute, doppelte Kundendatensätze
Value	Empfehlungsalgorithmus steigert durchschnittlichen Warenkorbwert

Big Data ist kein Mengenproblem allein. Die fünf Vs beschreiben ein Eigenschaftsprofil, das klassische Datenbanken systematisch überfordert. Jedes V erfordert andere architektonische Antworten.

Schlüsselbegriffe — Modul 1

Begriff	Erklärung
Big Data	Datensätze, die durch Volume, Variety, Velocity, Veracity oder Value klassische Verarbeitung überfordern
Volume	Datenmenge — von Gigabyte bis Petabyte und darüber hinaus
Variety	Vielfalt der Datenformate und -modelle (relational, Text, Graph, Stream)
Velocity	Geschwindigkeit, mit der Daten erzeugt und verarbeitet werden müssen
Veracity	Verlässlichkeit und Qualität der Daten; Unsicherheit über Korrektheit
Value	Nutzen, der durch Analyse und Anwendung aus Daten gewonnen wird
ETL	Extract, Transform, Load — klassischer Drei-Schritt-Prozess der Datenpipeline
Clickstream	Protokoll der Aktionen eines Nutzers auf einer Website

Modul 2

Speicher- und Verarbeitungsschichten

Leitfrage

Wie gewinnt man Wissen aus Daten?

Data Science — eine Einordnung

Data Science erforscht und wendet Technologien, Systeme und Algorithmen an, um Wissen aus potenziell großen, heterogenen und dynamisch veränderlichen Datensätzen zu gewinnen.

Data Science

Methoden und Systeme zur Wissensgewinnung aus Daten — verbindet Statistik, Informatik und Domänenwissen.

Machine Learning

Algorithmen, die aus vergangener Erfahrung lernen und Entscheidungen treffen, ohne explizit programmiert zu sein.

Artificial Intelligence

Systeme, die intelligentes Verhalten zeigen — ML ist der aktuell dominante Ansatz, AI der übergeordnete Begriff.

Deduktives vs. Induktives Schließen

Die Art, wie Wissen gewonnen wird, unterscheidet sich grundlegend:


Aspekt	Deduktives Schließen	Induktives Schließen
Ausgangspunkt	Gegebene Prämissen und Regeln	Beobachtete Datenmuster
Richtung	Allgemein → Spezifisch	Spezifisch → Allgemein
Ergebnis	Logisch notwendige Schlussfolgerungen	Wahrscheinliche Verallgemeinerungen
Beispiel	„Alle Menschen sind sterblich. Sokrates ist ein Mensch. → Sokrates ist sterblich.“	„Diese 10.000 Kunden kauften nach A auch B. → Empfehle B nach Kauf von A.“
Einsatz in DS	Regelbasierte Systeme, Constraint-Solving	Machine Learning, Data Mining

Data Science ist primär induktiv: Muster werden aus Daten extrahiert — keine vollständige Gewissheit, aber probabilistisch fundierte Aussagen.

Der KDD-Prozess

Knowledge Discovery in Databases (KDD) beschreibt den vollständigen Weg von Rohdaten zum Wissen:

KDD-Prozess (Knowledge Discovery in Databases)



- **Selection:** Auswahl relevanter Daten aus dem Gesamtbestand
- **Preprocessing:** Fehlende Werte, Duplikate, Ausreißer behandeln
- **Transformation:** Merkmale ableiten, Dimensionsreduktion
- **Data Mining:** Algorithmen auf transformierten Daten anwenden
- **Interpretation:** Gefundene Muster fachlich bewerten und validieren

In der Praxis wird der Prozess mehrfach durchlaufen. Neue Erkenntnisse im Mining-Schritt führen häufig zur Überarbeitung der Preprocessing-Schritte.

Data Mining Aufgaben im Überblick

Kategorie	Sub-Aufgabe	Beschreibung	Beispiel
Predictive	Classification	Klasse aus bekannten Attributen vorhersagen	Spam-Filter, Kreditrisiko
Predictive	Regression	Numerischen Wert vorhersagen	Preisvorhersage, Nachfrage
Predictive	Collaborative Filtering	Präferenzen aus ähnlichen Nutzern ableiten	Film-/Produktempfehlungen
Descriptive	Clustering	Ähnliche Objekte ohne Klassen gruppieren	Kundensegmentierung
Descriptive	Association Rules	Häufig gemeinsam auftretende Muster	Marktkorb-Analyse
Descriptive	Sequential Patterns	Zeitlich geordnete Muster	Klickpfad-Analyse
Explorative	Anomaly Detection	Abweichungen von Normalverhalten finden	Betrugserkennung

Classification: Vorhersage mit bekannten Klassen

Prinzip

1. **Trainingsdaten:** Datensatz mit bekanntem Klassen-Attribut
2. **Modelltraining:** Algorithmus lernt Entscheidungsregeln
3. **Testdaten:** Modell auf unbekannte Daten anwenden
4. **Evaluation:** Genauigkeit messen (Accuracy, F1, etc.)

Beispiel: Entscheidungsbaum

```
Alter > 30?  
├── Ja → Einkommen > 40k?  
│   ├── Ja → Kauf wahrscheinlich ✓  
│   └── Nein → Kauf unwahrscheinlich ✗  
└── Nein → Kauf unwahrscheinlich ✗
```

Einsatz

- E-Mail: Spam oder kein Spam?
- Medizin: Diagnose aus Symptomen
- Marketing: Kauft dieser Kunde?
- Kredit: Kreditausfall wahrscheinlich?

Algorithmen

- Decision Trees
- Random Forests
- Support Vector Machines
- Neural Networks

Clustering: Gruppierung ohne Klassen

Clustering findet natürliche Gruppen in Daten — ohne vorgegebene Klassen.

Beispiel: Kundensegmentierung

Cluster A: Jung, hohes Einkommen, Hochschule
→ Premium-Angebote, digitale Kanäle

Cluster B: Mittleres Alter, mittleres Einkommen
→ Familienprodukte, Newsletter

Cluster C: Senioren, niedriges Einkommen
→ Basistarife, persönliche Beratung

Eigenschaften

- kein Klassen-Attribut notwendig
- Anzahl der Cluster oft vorab wählen (k-Means)
- Ergebnisse erfordern fachliche Interpretation

Algorithmen

- k-Means (Partitionierung)
- DBSCAN (Dichtebasiert)
- Hierarchisches Clustering

Association Rule Mining

Findet Produkte oder Ereignisse, die häufig gemeinsam auftreten.

Marktkorb-Analyse

Transaktion	Produkte
T1	p1, p3, p5, p8
T2	p2, p5, p8
T3	p1, p5, p8
T4	p3, p4

Regel:

$\{p5\} \rightarrow \{p8\}$

mit Support 75%, Confidence 100%

→ Wer p5 kauft, kauft fast immer auch p8.

Anwendungen

- **Retail:** Platzierung verwandter Produkte
- **Online-Shop:** „Kunden, die X kauften, kauften auch Y“
- **Medizin:** Symptom-Diagnose-Korrelationen

Kennzahlen

- **Support:** Wie oft tritt die Regel auf?
- **Confidence:** Wie zuverlässig ist die Regel?
- **Lift:** Wie viel besser als Zufall?

Text Mining und Graph Mining

Text Mining

Klassische Data-Mining-Methoden auf Textdaten:

- **Web-Seiten clustern:** Ähnliche Themen automatisch gruppieren
- **Seiten klassifizieren:** Spam, Kategorie, Sentiment
- **Named Entity Recognition:** Personen, Orte, Unternehmen
- **Topic Modeling:** Latente Themenstrukturen finden

Herausforderung: Texte sind hochdimensional und dünn besetzt.

Graph Mining

Muster in Netzwerkdaten erkennen:

- **Community Detection:** Gruppen in sozialen Netzwerken
- **Link Prediction:** Wer wird mit wem verbunden?
- **Anomalie-Erkennung:** Ungewöhnliche Verbindungsmuster
- **Pagerank:** Zentrale Knoten im Netzwerk

Beispiel: Betrugserkennung über ungewöhnliche Transaktionsnetzwerke.

Mini-Übung: Mining-Aufgaben klassifizieren

Ordnen Sie die folgenden Anwendungen einer Mining-Kategorie zu: **Classification**, **Clustering**, **Regression** oder **Collaborative Filtering**.

Anwendung	Kategorie
Netflix empfiehlt Serien basierend auf ähnlichen Nutzerprofilen	?
Ein Modell schätzt den Verkaufspreis eines Hauses	?
Kunden werden nach Kaufverhalten in Gruppen eingeteilt	?
Eine Bank entscheidet: Kreditantrag genehmigen oder ablehnen?	?

Musterlösung

Anwendung	Kategorie
Netflix empfiehlt Serien basierend auf ähnlichen Nutzerprofilen	Collaborative Filtering
Ein Modell schätzt den Verkaufspreis eines Hauses	Regression
Kunden werden nach Kaufverhalten in Gruppen eingeteilt	Clustering
Eine Bank entscheidet: Kreditantrag genehmigen oder ablehnen?	Classification

Data Science ist die Disziplin, die aus Daten belastbares Wissen macht — durch den KDD-Prozess, induktive Lernmethoden und iterative Modellentwicklung. Wer die Aufgabe falsch wählt, erhält richtige Antworten auf die falsche Frage.

Modul 3


Batch, Streaming und Orchestrierung

Leitfrage

Wie verarbeitet man Daten im Petabyte-Maßstab?

Das klassische Werkzeug: Data Warehouse

Bevor Big Data die Annahmen sprengte, war das **Data Warehouse (DWH)** die Standardantwort für analytische Datenhaltung:



- **ETL:** Daten extrahieren, transformieren, laden — klassisch
- **ELT:** Erst laden (Rohdaten erhalten), dann im Zielsystem transformieren — modern

OLAP vs. OLTP

Aspekt	OLTP	OLAP
Zweck	Transaktionen	Analysen
Abfragen	viele, kurz	wenige, komplex
Daten	aktuell	historisch
Beispiel	Bestellsystem	Quartalsbericht


Star Schema

- **Faktentabelle:** Große Akkumulation numerischer Fakten
- **Dimensionstabellen:** Statische Beschreibungen von Entitäten
- **Maßzahlen:** Aggregate über Dimensionen

Star Schema: Datenmodell



Star Schema



Warum das DWH an Grenzen stößt

Die Fünf Vs stellen die Grundannahmen klassischer DWH-Systeme direkt in Frage:

Annahme des DWH	Herausforderung durch Big Data
Daten passen auf einen großen Server	Volume: Petabyte-Mengen erfordern Verteilung
Schema ist vorab bekannt	Variety: JSON, Logs, Graphen, Streams
ETL läuft nachts, Latenz ist akzeptabel	Velocity: Echtzeit-Anforderungen
Quelldaten sind verlässlich	Veracity: Systematische Qualitätsprobleme
Analytischer Mehrwert rechtfertigt Aufwand	Value: Kosten-Nutzen-Relation bei Rohdaten unklar

Scaling Up vs. Scaling Out

Scaling Up vs. Scaling Out

Vertical Scaling (Scale Up)

2 CPU
16 GB



64 CPU
2 TB RAM
10.000 \$/Mo

- + Einfach (ACID funktioniert)
- + Keine verteilte Koordination
- Hardware-Maximum erreicht
- Kosten steigen überproportional

Typisch: RDBMS, DWH

Horizontal Scaling (Scale Out)

Node 1

Node 2

Node 3

Node 4

Node 5

Node 6

... N

je 100 \$/Mo

- + Linear skalierbar
 - + Ausfalltoleranz durch Redundanz
 - Verteilte Koordination nötig
 - CAP-Theorem: C vs. A
- Typisch: HDFS, Spark, Cassandra*

Vertical Scaling (Scale Up)


- Größere, leistungstärkere Einzelmaschine
- RDBMS mit ACID-Garantien funktionieren gut
- Grenze: Hardware-Maximum irgendwann erreicht
- Kosten steigen überproportional

Horizontal Scaling (Scale Out)

- Viele kleine, günstige Standard-Maschinen
- Jenseits eines Schwellwerts günstiger als Scale Up
- Erfordert verteilte Algorithmen und Koordination
- Ausfalltoleranz durch Redundanz

CAP-Theorem: Die Grenzen verteilter Systeme

CAP-Theorem (Brewer, 2000)



CAP-Theorem (Brewer, 2000): In einem verteilten System können nicht gleichzeitig alle drei Eigenschaften garantiert werden — es müssen zwei gewählt werden.

CA

A

P

Partition Tol.

Eigenschaft	Bedeutung
Consistency (C)	Alle Knoten sehen denselben, aktuellen Zustand
Availability (A)	Jede Anfrage erhält eine (möglicherweise veraltete) Antwort
Partition Tolerance (P)	System funktioniert auch bei Netzwerkausfall zwischen Knoten

Systemtypen in der Praxis

Typ	Systeme
CP	HBase, MongoDB (strong), Zookeeper
AP	Cassandra, CouchDB, DynamoDB
CA	Klassische RDBMS (nur ohne Partition)

lich → Wahl zwischen C und A

In der Praxis:
P muss immer gegeben sein
. Die Wahl liegt zwischen
C
und
A
.



Der Paradigmenwechsel: SWAPPING zu CLUSTERING

Traditionell: SWAPPING

Disk → RAM → Cache → Register

- Daten werden Block für Block von Disk geladen
- Einzelne Maschine verarbeitet sequenziell
- Google indiziert ~10 Mrd. Seiten = 200 TB
- Bei 50 MB/s Bandbreite: **40 Tage** nur zum Lesen

Selbst der schnellste Einzelrechner ist zu langsam für Petabyte-Datenmengen.

Big Data: CLUSTERING

```
[Node 1: 10 GB Chunk] ↔ Computation  
[Node 2: 10 GB Chunk] ↔ Computation  
[Node 3: 10 GB Chunk] ↔ Computation  
... 1000 Nodes
```

- Daten in Chunks aufteilen, auf Nodes verteilen
- 200 TB / 1000 Nodes = **200 GB pro Node**
- Computation kommt zu den Daten

Data Locality:

Code wird dorthin geschickt, wo die Daten liegen.

Netzwerk und Ausfalltoleranz im Cluster

Netzwerk-Bandbreite

- Innerhalb eines Racks: **1 Gbps**
- Rack-übergreifend (Backbone): **2–10 Gbps**
- Daten-Reshuffling ist teuer: 10 TB bei 1 GB/s = **2,8 Stunden**
- Faustregel: **Reshuffling minimieren**

Ausfalltoleranz

- Bei **1000 Servern**: statistisch ~1 Ausfall pro Tag
- Bei **1.000.000 Maschinen** (Google): ~1000 Ausfälle täglich
- Ausfälle sind keine Ausnahmen — sie sind der **Normalzustand**

Konsequenz:

- Daten mehrfach replizieren
- Berechnungen bei Ausfall automatisch neu starten
- Kein Job darf an einem einzelnen Knoten hängen


Design for Failure: Verteilte Systeme müssen von Anfang an auf Ausfälle ausgelegt sein — nicht nachträglich abgesichert werden.

HDFS: Verteiltes Dateisystem

Das Hadoop Distributed File System (HDFS) implementiert das Clustering-Paradigma:



HDFS — Hadoop Distributed File System



MapReduce: Berechnung auf verteilten Daten

Google's Programmiermodell für verteilte Datenverarbeitung — heute Grundlage von Hadoop:

Phasen


1. **Map:** Für jedes $\langle \text{key}, \text{value} \rangle$ -Paar: erzeugt eine Menge von $\langle k', v' \rangle$ -Paaren
2. **Shuffle & Sort:** Intermediäre Paare werden nach Key gruppiert und sortiert
3. **Reduce:** Für jede Gruppe von $\langle k', v' \rangle$ -Paaren: berechnet ein Aggregat

Effizienz-Prinzipien

- **Streaming through data:** Sequenzielles Lesen ohne Disk Seeks
- **Data Locality:** Map-Tasks laufen auf dem Knoten mit dem jeweiligen Chunk
- **Automatische Fehlerbehandlung:** Fehlgeschlagene Tasks werden neu gestartet

MapReduce Beispiel: Wörter zählen

MapReduce: Word Count Beispiel



map(key, value):

```
for word in value.split():  
    emit(word, 1)
```

reduce(key, values):

```
emit(key, sum(values))
```

Effizienz-Prinzipien:

1. Data Locality — Map läuft auf dem Chunk-Node
2. Streaming — Sequenzielles Lesen, keine Seeks
3. Parallelisierung — alle Mapper gleichzeitig
4. Fehlertoleranz — Tasks automatisch neu starten

```
# Pseudo-Code: MapReduce Wortfrequenz  
def map_fn(key, value):  
    # value = Zeile des Dokuments  
    for word in value.split():  
        emit(word, 1)  
  
def reduce_fn(key, values):  
    # key = Wort, values = [1, 1, 1, ...]  
    emit(key, sum(values))
```

Stream-Zeitmodelle: Warum Reihenfolge trügt

Im Streaming ist Zeit nicht trivial — dasselbe Event hat drei verschiedene Zeitstempel:

Stream-Zeitmodelle


Event Time

Wann ist das Event tatsächlich passiert?



Ingestion Time

Wann ist das Event beim Broker (Kafka) eingetroffen?



Processing Time


Wann hat Flink/Spark das Event verarbeitet?



Kernproblem: Events treffen nicht in der Reihenfolge ein, in der sie passiert sind. Stream-Systeme brauchen Watermarks und Windowing, um damit umzugehen.

Backpressure und Exactly-Once-Semantik

Zwei zentrale Herausforderungen im Stream Processing:



Batch vs. Streaming: Wann was einsetzen?

Batch-Verarbeitung

- Daten werden gesammelt und periodisch als Block verarbeitet
- **Stärken:** Hoher Durchsatz, Einfachheit, Kosteneffizienz
- **Schwächen:** Hohe Latenz (Minuten bis Stunden)
- **Einsatz:** Reporting, ML-Training, historische Analysen, ETL



Stream-Verarbeitung

- Jedes Event wird sofort nach Eintreffen verarbeitet
- **Stärken:** Niedrige Latenz (Millisekunden)
- **Schwächen:** Komplexer (Out-of-Order, Duplikate, Checkpoints)
- **Einsatz:** Betrugserkennung, Alerting, Echtzeit-Empfehlungen

Kriterium	Batch	Stream
Latenz	Minuten–Stunden	Millisekunden–Sekunden
Fehlerbehandlung	Neuberechnung des Batches	Checkpoints, Exactly-once
Engineering-Aufwand	geringer	höher
Wirtschaftlichkeit	günstiger bei großen Mengen	teurer bei hohem Volumen

Lambda- und Kappa-Architektur

Lambda- vs. Kappa-Architektur



Aspekt	Lambda	Kappa
Verarbeitungspfade	Zwei (Batch + Stream)	Einer (nur Stream)
Codebasis	Doppelt	Einfach
Historische Daten	Batch Layer	Replay aus Event-Log
Betriebsaufwand	Hoch	Geringer
Genauigkeit (historisch)	Exakt	Abhängig von Log-Tiefe

Lambda-Architektur: Batch + Stream kombiniert

Problem: Wie bekommt man historische Vollständigkeit **und** Echtzeit-Ergebnisse?

Struktur

- **Batch Layer** (Spark, Hadoop): Vollständige historische Neuberechnung periodisch — exakt, aber verzögert
- **Speed Layer** (Flink, Kafka Streams): Nur neue Events seit letztem Batch — sofortige, approximierte Ergebnisse
- **Serving Layer:** Kombiniert beide Pfade für Abfragen

Nachteil — Doppelte Codebasis: Dieselbe Verarbeitungslogik muss für Batch (z.B. Spark) **und** Stream (z.B. Flink) implementiert und synchron gehalten werden. Hoher Betriebsaufwand.

Kappa-Architektur: Nur Streaming

Idee: Wenn Stream-Systeme robust genug sind — warum noch Batch?

Struktur

- **Alle Daten** als Events im persistenten Log (Kafka)
- **Eine Codebasis** — dieselbe Logik für neue Events und historische Daten
- **Replay**: Bei Logik-Änderungen gesamtes Log erneut durchlaufen → konsistente Neuberechnung

Aspekt	Lambda	Kappa
Verarbeitungspfade	zwei (Batch + Stream)	einer (nur Stream)
Codebasis	doppelt	einfach
Historische Daten	Batch Layer	Replay aus Event-Log
Betriebsaufwand	hoch	geringer

Mini-Übung: Batch oder Streaming?

Entscheiden Sie für jedes Szenario: **Batch** oder **Streaming** — und begründen Sie kurz.

Szenario	Batch oder Streaming?
Tagesabschluss-Bericht der Verkaufszahlen	?
Erkennen eines Kreditkartenbetrugs in Echtzeit	?
Wöchentlicher ML-Trainings-Job auf historischen Klick-Daten	?
Alerting bei Serverausfall innerhalb von 5 Sekunden	?
Monatliche Kundensegmentierung für E-Mail-Kampagne	?

Musterlösung

Szenario	Entscheidung	Begründung
Tagesabschluss-Bericht	Batch	Latenz von Stunden akzeptabel, hoher Durchsatz
Kreditkartenbetrug	Streaming	Muss in Millisekunden entschieden werden
ML-Trainings-Job	Batch	Vollständiger historischer Datensatz nötig
Server-Alerting	Streaming	Reaktionszeit < 5 Sekunden erforderlich
Kundensegmentierung	Batch	Monatlicher Rhythmus, kein Echtzeit-Bedarf

Batch und Stream sind keine Konkurrenten, sondern komplementäre Werkzeuge. Die Wahl hängt von Latenzbedarf, Durchsatz und Konsistenzanforderungen ab — nicht von technischer Mode.

Modul 4

Datenqualität und Governance

Leitfrage

Was macht eine robuste Datenplattform aus — und warum scheitern datengetriebene Systeme oft nicht an Rechenleistung, sondern an Qualität, Verantwortlichkeiten und fehlender Transparenz?

MapReduce: Effizienz durch Lokalität

Warum ist MapReduce so schnell, obwohl es auf tausenden günstiger Maschinen läuft?

Prinzip	Erklärung
Data Locality	Map-Task läuft auf dem Node, der den Chunk speichert — kein Netzwerktransfer für Eingabedaten
Streaming	Daten werden sequenziell gelesen, keine Disk-Seekes — maximale Bandbreite
Pipelining	Map-Tasks laufen parallel auf allen Nodes — horizontale Skalierung
Fehlertoleranz	Framework re-startet fehlgeschlagene Tasks automatisch auf Replikat

Data Locality Principle


Code ist klein (wenige KB), Daten sind riesig (TB).
Bringe die Berechnung zu den Daten
, nicht umgekehrt.

Geeignete Anwendungen:

- Web-Index-Aufbau (Google!)
- Log-Analyse
- ETL-Pipelines
- ML-Feature-Berechnung

Hadoop Ökosystem

Hadoop Ökosystem



Schicht	Technologien	Aufgabe
Anwendungen	MapReduce, Spark, Hive, Pig, Storm, Giraph	Datenverarbeitung (Batch, Streaming, Graph, SQL)



Schicht	Technologien	Aufgabe
Ressourcenmanagement	YARN	Zuweisung von CPU, RAM an Anwendungen im Cluster
Speicher	HDFS	Verteilte, redundante Datenhaltung in Chunks

Hadoop ≠ MapReduce: MapReduce ist nur **eine** Anwendung auf Hadoop. Moderne Stacks nutzen meist Spark (In-Memory, 10–100× schneller) auf YARN/HDFS.

Alternativen zum Scale-Out

Master/Slave Replikation

- Originaler GFS-Ansatz
- Multi-Master-Replikation möglich
- **INSERT only** — keine Updates/Deletes
- Keine JOINS → reduziert Query-Zeit
- Lesezugriff skaliert durch Replicas

Einsatz:

Leselastige Systeme, Content-Delivery

In-Memory-Datenbanken

- Gesamte Datenbank im RAM
- SAP HANA, Oracle In-Memory, Redis
- Extrem geringe Latenz
- Teuer, aber ideal für Echtzeitanalysen

Einsatz:


Echtzeit-Dashboards, Trading-Systeme

Managed Cloud-Services

- BigQuery, Redshift, Snowflake
- Serverless, automatisches Scaling
- Pay-per-Query statt Cluster-Management

Datenqualität: Die fünf Dimensionen

Dimension	Prüffrage	Beispiel
Vollständigkeit	Fehlen Werte?	15 % der Bestellungen ohne PLZ
Konsistenz	Widersprechen sich Quellen?	CRM sagt 500 Kunden, DWH sagt 480
Aktualität	Sind Daten frisch genug?	Lagerbestand 6 Stunden veraltet
Genauigkeit	Stimmen die Werte?	GPS-Koordinaten auf falscher Straße
Eindeutigkeit	Gibt es Duplikate?	Gleicher Kunde mit 3 IDs



Qualität ist kein Feature, sondern ein Prozess: kontinuierlich messen, automatisiert prüfen, bei Verstößen alarmieren — wie Software-Tests.

Quality Gates in der Pipeline

Pipeline-Stufe	Quality Gate	Tool-Beispiel
Ingestion	Schema-Validierung, Vollständigkeit, Format	Great Expectations, JSON Schema
Transformation	Referentielle Integrität, Wertebereiche	dbt tests, SQL assertions
Aggregation	Plausibilitätsprüfung, Ausreißer-Erkennung	Statistische Bounds, z-Score
Serving	Freshness-Check, SLA-Monitoring	Airflow SLAs, Monte Carlo

Was passiert bei Qualitätsverstößen?

Strategie	Wann?
Quarantäne	Fehlerhafte Datensätze in separaten Bereich verschieben
Abort	Pipeline stoppen, wenn kritische Schwelle überschritten
Alert	Team benachrichtigen, Daten weiterverarbeiten
Auto-Fix	Imputation fehlender Werte, Deduplication

Keine dieser Strategien ist universell richtig — die Wahl hängt vom Business-Kontext ab: Ein fehlender Sensorwert im IoT-Dashboard ist weniger kritisch als ein fehlerhafter Finanzwert.

Data Governance: Wer ist verantwortlich?

Governance-Frage	Warum wichtig?
Ownership: Wem gehört dieses Datenprodukt?	Ohne Eigentümer wird kein Bug gefixt
Definitionen: Was bedeutet „aktiver Kunde“?	Verschiedene Teams zählen unterschiedlich
Zugriffsrechte: Wer darf was sehen?	DSGVO, PII, Compliance
Lineage: Woher kommen diese Daten?	Debugging, Audit, Vertrauenswürdigkeit
Retention: Wie lange speichern wir?	Speicherkosten, Recht auf Löschung


Data Catalog

Ein
Data Catalog
ist das „Google für interne Daten“:

- Beschreibung jedes Datensatzes
- Eigentümer und Kontaktperson
- Schema, Datentypen, Beispielwerte
- Lineage-Graph (Herkunft)
- Qualitätsmetriken

Beispiele:
DataHub, Apache Atlas, Alation, Google Data Catalog

Data Lineage: Herkunft nachvollziehen



Warum Lineage unverzichtbar ist:

- **Debugging:** Ein Wert im Dashboard ist falsch — welche Transformation hat den Fehler eingeführt?
- **Impact Analysis:** Wir ändern das Schema einer Quelltable — welche Downstream-Systeme brechen?
- **Compliance:** Die DSGVO verlangt Auskunft, wo personenbezogene Daten verarbeitet werden
- **Vertrauen:** Data Scientists müssen wissen, ob sie einem Datensatz vertrauen können

Mini-Übung: Quality Check Design

Ein Online-Shop hat eine Produktdaten-Pipeline: Lieferanten-CSV → Ingestion → Transformation → Data Warehouse → Produktkatalog-API.

Entwerfen Sie für jede Pipeline-Stufe **einen konkreten Quality Check**:

Stufe	Was prüfen Sie?	Erwartetes Ergebnis
Ingestion	?	?
Transformation	?	?
Data Warehouse	?	?
API	?	?

Musterlösung

Stufe	Quality Check	Erwartung
Ingestion	CSV hat alle Pflichtfelder (EAN, Name, Preis)	Keine Zeile ohne EAN
Transformation	Preis > 0 und < 100.000 €	Keine negativen oder absurd hohen Preise
Data Warehouse	Anzahl Produkte ändert sich max. 5 % pro Tag	Keine Masseninsertions/-löschungen ohne Grund
API	Response enthält ≥ 95 % der Warehouse-Produkte	Keine stillen Datenverluste beim Serving

Gesamtüberblick: Vom Data Warehouse zu Big Data

Aspekt	Klassisches DWH	Big Data / Cloud
Skalierung	Vertikal (größerer Server)	Horizontal (mehr Nodes)
Datenmodell	Star Schema, strukturiert	Schema-on-Read, polyglot
Verarbeitung	ETL → OLAP	MapReduce, Spark, Streaming
Speicher	RDBMS (Oracle, Teradata)	HDFS, S3, Cloud Storage
Latenz	Stunden (Batch-ETL)	Sekunden (Streaming)
Kosten	Hohe Lizenzkosten, wenige Server	Commodity-Hardware, Pay-per-Use
Qualität	Manuell, selten geprüft	Automatisierte Quality Gates
Governance	Zentral (IT-Abteilung)	Dezentral (Data Mesh / Domain Ownership)

Kein Entweder-Oder: Moderne Datenplattformen kombinieren DWH-Konzepte (Star Schema, SQL) mit Big-Data-Technologien (Spark, Cloud Storage). Das „Lakehouse“-Muster vereint Data Lake und Data Warehouse.



Data Engineering scheitert selten an Rechenleistung. Es scheitert an unklaren Eigentümerschaften, fehlender Lineage, veralteten Definitionen und ungeprüften Annahmen. Qualität, Governance und Transparenz sind keine Add-ons — sie

sind das Fundament jeder belastbaren Datenplattform.

Wrap-Up

- Data Engineering organisiert den Weg von Datenquellen zu verlässlichen, nutzbaren Datenprodukten.
- Architekturentscheidungen zu Speicher, Verarbeitung und Orchestrierung bestimmen Skalierbarkeit und Reaktionszeit.
- Ohne Datenqualität, Metadaten und Governance werden selbst technisch funktionierende Pipelines fachlich unbrauchbar.